

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA CÔNG NGHỆ PHẦN MỀM

PHÁT HIỆN XU HƯỚNG XÃ HỘI THEO THỜI GIAN THỰC

LỚP: SE363.Q11

GV HƯỚNG DẪN:

TS. Đỗ Trọng Hợp

NHÓM 7:

Quách Gia Kiệt - 23520819

Phạm Thành Long - 23520887

Huỳnh Trần Anh Thư - 23521535

TP. HỒ CHÍ MINH, 2025

LỜI CẢM ƠN

Nhóm chúng em xin gửi lời cảm ơn và lòng biết ơn sâu sắc nhất tới thầy Đỗ Trọng Hợp, giảng viên hướng dẫn cho nhóm. Thầy đã luôn nhiệt tình, đồng hành, hỗ trợ và giúp đỡ chúng em trong suốt quá trình thực hiện đồ án môn học

Trong thời gian một học kỳ thực hiện đề tài, nhóm chúng em đã vận dụng những kiến thức nền tảng đã tích lũy đồng thời kết hợp với việc học hỏi và nghiên cứu những kiến thức mới, và đặc biệt là những kiến thức từ lý thuyết đến thực hành mà thầy đã nhiệt huyết giảng dạy cho chúng em. Từ đó, nhóm chúng em vận dụng tối đa những gì đã thu thập được để hoàn thành một báo cáo đồ án tốt nhất.

Trong quá trình thực hiện đồ án này, với kinh nghiệm và thời gian có hạn, nhóm không tránh khỏi được sai sót, chúng em kính mong nhận được sự góp ý, hướng dẫn của thầy để có thể hoàn thiện đồ án hơn nữa, cũng như là hành trang để nhóm chúng em thực hiện tiếp các đề tài khác trong tương lai.

Nhóm em xin chân thành cảm ơn thầy!

Nhóm sinh viên thực hiện
Quách Gia Kiệt
Phạm Thành Long
Huỳnh Trần Anh Thư

Mục lục

Lời cảm ơn	1
Tóm tắt đồ án	1
1 Mở đầu	4
1.1 Lý do chọn đề tài	4
1.2 Mục đích	4
1.3 Đối tượng nghiên cứu	5
1.4 Phạm vi nghiên cứu	5
2 Cơ sở lý thuyết	7
2.1 Apache Kafka	7
2.2 Apache Spark	7
2.3 Vector Embeddings	8
2.4 HDBSCAN	8
2.5 Large Language Models	9
3 Kết quả thực hiện	10
3.1 Kiến trúc tổng thể hệ thống	10
3.2 Tầng thu thập dữ liệu (Producer)	12
3.2.1 Thu thập từ TikTok	12
3.2.2 Thu thập từ YouTube	12
3.2.3 Thu thập từ News	12
3.2.4 Kafka Producer	13
3.2.5 Keyword Extractor	13
3.3 Tầng xử lý phân tích (Consumer)	14
3.3.1 Kafka Consumer	14
3.3.2 Pipeline xử lý 8 giai đoạn	14
3.3.3 Cơ chế xử lý lỗi	18

3.4	Tầng giao diện (Dashboard)	18
3.4.1	User Dashboard	18
3.4.2	Admin Dashboard	19
4	Kết luận	21
4.1	Kết quả đạt được	21
4.2	Hạn chế và thách thức	22
4.3	Đánh giá chung	22
5	Hướng phát triển	24
	Tài liệu tham khảo	26

TÓM TẮT ĐỒ ÁN

Vấn đề nghiên cứu

Trong bối cảnh mạng xã hội phát triển mạnh mẽ với hơn 5 tỷ người dùng toàn cầu, việc theo dõi và phát hiện các xu hướng đang nổi lên trở nên vô cùng quan trọng đối với các nhà tiếp thị, quản lý mạng xã hội và doanh nghiệp. Mỗi ngày, hàng triệu nội dung mới được tạo ra trên các nền tảng như TikTok, YouTube và các trang tin tức, tạo nên một khối lượng dữ liệu khổng lồ. Trong đó ẩn chứa các xu hướng - những chủ đề, sự kiện hoặc hiện tượng đang thu hút sự quan tâm đặc biệt của cộng đồng. Việc phát hiện và phân tích các xu hướng này sớm giúp doanh nghiệp điều chỉnh chiến lược marketing kịp thời, nhà báo nắm bắt các vấn đề xã hội nổi cộm, và quản lý mạng xã hội kiểm soát nội dung tiêu cực.

Tuy nhiên, việc theo dõi xu hướng từ nhiều nền tảng khác nhau hiện nay vẫn là một thách thức lớn. Hầu hết các công cụ hiện có chỉ tập trung vào một nền tảng duy nhất hoặc cung cấp dữ liệu thống kê đơn thuần mà không có phân tích chuyên sâu. Các phương pháp thủ công yêu cầu người dùng phải liên tục kiểm tra từng nền tảng, tốn thời gian và dễ bỏ sót thông tin quan trọng. Đặc biệt, việc tổng hợp và phân tích xu hướng đa nền tảng - khi một chủ đề xuất hiện đồng thời trên nhiều kênh - đòi hỏi kỹ năng và công sức vượt quá khả năng của hầu hết người dùng và tổ chức.

Cách giải quyết vấn đề

Để giải quyết vấn đề trên, đồ án xây dựng một hệ thống phát hiện xu hướng xã hội theo thời gian thực sử dụng kiến trúc kết hợp ba tầng chính: thu thập dữ liệu, xử lý phân tích, và giao diện người dùng.

Tầng thu thập dữ liệu sử dụng các API và công cụ scraping để tự động lấy nội dung từ ba nguồn chính: TikTok (qua Apify API), YouTube (qua YouTube Data API v3), và các trang tin tức trực tuyến Việt Nam (qua RSS feeds). Dữ liệu được gửi vào Apache Kafka - một hàng đợi tin nhắn phân tán đảm bảo tính ổn định và khả năng mở rộng.

Tầng xử lý phân tích sử dụng PySpark để xử lý batch dữ liệu qua pipeline tám giai đoạn: (1) chuẩn hóa dữ liệu từ các nguồn khác nhau về schema thống nhất; (2) làm sạch và kiểm tra tính hợp lệ; (3) lọc chất lượng để loại bỏ spam, bot dựa trên các chỉ số như tỷ lệ tương tác tối thiểu 1%, số người theo dõi tối thiểu 1000; (4) chuyển đổi văn bản thành vector embedding 1536 chiều bằng OpenAI hoặc Gemini; (5) phân cụm nội dung tương đồng bằng thuật toán HDBSCAN với kích thước cụm tối thiểu 15 items; (6) phân tích từng cụm bằng mô hình ngôn ngữ lớn (LLM) để trích xuất chủ đề, tóm tắt, phân tích cảm xúc, đánh giá rủi ro và tạo hướng dẫn sử dụng; (7) khử trùng với các xu hướng đã có sử dụng chiến lược đa yếu tố (embedding similarity, keyword overlap, source distribution) với ngưỡng 0.75; (8) lưu trữ vào MongoDB và tự động xóa xu hướng cũ hơn 3 ngày.

Tầng giao diện người dùng được xây dựng bằng Streamlit, cung cấp hai dashboard: dashboard người dùng để xem xu hướng với đầy đủ thông tin phân tích, và dashboard quản trị để quản lý xu hướng, duyệt đề xuất từ khóa từ người dùng. Toàn bộ hệ thống được đóng gói bằng Docker để dễ dàng triển khai và vận hành.

Kết quả đạt được

Đồ án đã xây dựng thành công một hệ thống phát hiện xu hướng xã hội hoàn chỉnh có khả năng tự động vận hành mỗi bốn giờ mà không cần can thiệp thủ công. Hệ thống có thể xử lý khoảng 1500-2000 nội dung mỗi lần chạy từ ba nguồn TikTok, YouTube và News, phát hiện các cụm xu hướng, và cung cấp phân tích chuyên sâu cho từng xu hướng.

Dashboard người dùng hiển thị các xu hướng được sắp xếp theo mức độ tương tác (lượt xem và lượt thích), với đầy đủ thông tin như chủ đề, tóm tắt, cảm xúc (tích cực/tiêu cực/trung lập), mức độ rủi ro (an toàn/thận trọng/rủi ro cao/nguy hiểm), loại nội dung (giải trí/drama/nguy hiểm/vấn đề xã hội/thương mại), và phân bố nguồn. Đặc biệt, hệ thống tự động tạo ra các hướng dẫn cụ thể cho marketer và quản lý mạng xã hội về cơ hội và rủi ro khi tham gia vào từng xu hướng. Dashboard quản trị cho phép quản lý xu hướng, duyệt và phê duyệt từ khóa đề xuất từ người dùng, và theo dõi lịch sử thay đổi từ khóa.

Hệ thống đã được triển khai thành công với Docker, đảm bảo tính nhất quán giữa các môi trường phát triển và production. Cơ chế checkpoint của consumer đảm bảo không bị mất dữ liệu khi xử lý thất bại, và cơ chế timeout tự động dọn dẹp xu hướng

cũ giúp database luôn chứa thông tin mới nhất. Tuy nhiên, hệ thống còn một số hạn chế như chưa hỗ trợ xử lý streaming thời gian thực hoàn toàn, chỉ tập trung vào ba nền tảng chính, và cần tối ưu hóa thêm về chi phí API LLM.

Bất chấp những hạn chế này, kết quả đạt được chứng minh rằng kiến trúc tích hợp Kafka, PySpark, HDBSCAN và LLM có khả năng hoạt động hiệu quả trong việc xây dựng hệ thống phát hiện xu hướng đa nền tảng. Đề án mở ra các cơ hội để mở rộng sang các nền tảng khác như Facebook, Twitter/X, tích hợp xử lý streaming thời gian thực, và áp dụng các kỹ thuật học sâu tiên tiến hơn cho dự đoán xu hướng trong tương lai.

Chương 1 Mở đầu

1.1 Lý do chọn đề tài

Trong kỷ nguyên số hiện nay, mạng xã hội đã trở thành một phần không thể thiếu trong cuộc sống của hàng tỷ người trên toàn thế giới. Theo thống kê của DataReportal năm 2024, có hơn 5 tỷ người dùng mạng xã hội toàn cầu, chiếm khoảng 62% dân số thế giới. Tại Việt Nam, con số này còn cao hơn với hơn 77 triệu người dùng, chiếm 76.9% dân số. Mỗi ngày, hàng triệu nội dung mới được tạo ra trên các nền tảng như TikTok, YouTube và các trang tin tức, tạo nên một khối lượng dữ liệu khổng lồ.

Trong khối lượng dữ liệu này ẩn chứa các xu hướng - những chủ đề, sự kiện hoặc hiện tượng đang thu hút sự quan tâm đặc biệt của cộng đồng trong một khoảng thời gian nhất định. Việc phát hiện và phân tích các xu hướng sớm mang lại nhiều lợi ích: doanh nghiệp có thể điều chỉnh chiến lược marketing kịp thời, nhà báo có thể nắm bắt các vấn đề xã hội đang nổi cộm, và các nhà quản lý mạng xã hội có thể kiểm soát nội dung tiêu cực trước khi lan rộng.

Tuy nhiên, việc theo dõi xu hướng từ nhiều nền tảng khác nhau hiện nay vẫn là một thách thức lớn. Hầu hết các công cụ hiện có như Google Trends, TikTok Creative Center chỉ tập trung vào một nền tảng duy nhất hoặc cung cấp dữ liệu thống kê đơn thuần mà không có phân tích chuyên sâu. Các phương pháp thủ công yêu cầu người dùng phải liên tục kiểm tra từng nền tảng, tốn thời gian và dễ bỏ sót thông tin quan trọng. Đặc biệt, việc tổng hợp và phân tích xu hướng đa nền tảng - khi một chủ đề xuất hiện đồng thời trên nhiều kênh - đòi hỏi kỹ năng và công sức vượt quá khả năng của hầu hết người dùng và tổ chức.

Nhận thấy vấn đề này, nhóm thực hiện quyết định xây dựng một hệ thống phát hiện xu hướng xã hội theo thời gian thực có khả năng tự động thu thập, xử lý và phân tích dữ liệu từ nhiều nguồn mạng xã hội, từ đó phát hiện các xu hướng đang nổi lên và cung cấp phân tích chuyên sâu một cách kịp thời và chính xác.

1.2 Mục đích

Đồ án có mục đích xây dựng một hệ thống hoàn chỉnh có khả năng tự động phát hiện và phân tích xu hướng trên các nền tảng mạng xã hội phổ biến tại Việt Nam. Cụ thể, hệ thống sẽ thu thập dữ liệu từ ba nguồn chính (TikTok, YouTube, và các trang tin

tức trực tuyến), xử lý và phân cụm nội dung tương đồng bằng các thuật toán học máy, sau đó phân tích chuyên sâu về chủ đề, cảm xúc, mức độ rủi ro và cung cấp khuyến nghị cụ thể cho người dùng.

Bên cạnh đó, đồ án cũng nhằm chứng minh khả năng tích hợp và ứng dụng thực tế các công nghệ hiện đại trong xử lý dữ liệu lớn và phân tích thông minh. Hệ thống kết hợp Apache Kafka cho message queue, PySpark cho xử lý batch, thuật toán HDBSCAN cho phân cụm mật độ, và các mô hình ngôn ngữ lớn (GPT-4, Gemini) cho phân tích ngữ nghĩa. Đồ án hướng đến việc tạo ra một công cụ thực tế có thể triển khai và sử dụng, không chỉ dừng lại ở nghiên cứu lý thuyết.

1.3 Đối tượng nghiên cứu

Đối tượng nghiên cứu của đồ án bao gồm các nhà tiếp thị, quản lý mạng xã hội, nhà nghiên cứu thị trường, và các doanh nghiệp cần nắm bắt xu hướng để đưa ra quyết định chiến lược. Đặc biệt, hệ thống tập trung vào thị trường Việt Nam với nội dung chủ yếu bằng tiếng Việt, phù hợp với nhu cầu của các tổ chức và doanh nghiệp trong nước.

Ngoài ra, đồ án cũng hướng đến cộng đồng nghiên cứu và phát triển phần mềm quan tâm đến các lĩnh vực xử lý dữ liệu lớn, phân tích mạng xã hội, và ứng dụng học máy. Kiến trúc và mã nguồn của hệ thống có thể được sử dụng làm tài liệu tham khảo cho các dự án tương tự hoặc mở rộng cho các nền tảng mạng xã hội khác.

1.4 Phạm vi nghiên cứu

Phạm vi nghiên cứu của đồ án được giới hạn trong các khía cạnh sau:

Về nguồn dữ liệu: Hệ thống tập trung vào ba nền tảng chính là TikTok (video ngắn), YouTube (video dài), và các trang tin tức trực tuyến Việt Nam (VNExpress, Tuổi Trẻ, VTC News, Thanh Niên). Đồ án không bao gồm các nền tảng khác như Facebook, Instagram, Twitter/X do hạn chế về thời gian và khả năng truy cập API. Ngôn ngữ chủ yếu là tiếng Việt, hỗ trợ một phần tiếng Anh.

Về phương pháp xử lý: Hệ thống sử dụng xử lý batch (theo lô) với chu kỳ bốn giờ một lần, chưa triển khai xử lý streaming thời gian thực hoàn toàn. Pipeline xử lý bao gồm tám giai đoạn: chuẩn hóa, làm sạch, lọc chất lượng, embedding, phân cụm, phân tích, khử trùng và lưu trữ. Thuật toán phân cụm sử dụng HDBSCAN với kích thước cụm tối thiểu 15 nội dung.

Về quy mô: Hệ thống được thiết kế để xử lý khoảng 1500-2000 nội dung mỗi lần chạy, tương đương với khoảng 100 video TikTok, 200 video YouTube và 100+ bài báo mỗi nguồn. Thời gian xử lý một batch từ 10-15 phút tùy thuộc vào số lượng cụm được phát hiện và tốc độ phản hồi của API mô hình ngôn ngữ.

Về triển khai: Hệ thống được phát triển dưới dạng ứng dụng web với giao diện Streamlit, có thể chạy trên môi trường local hoặc triển khai trên cloud. Toàn bộ hệ thống được đóng gói bằng Docker để đảm bảo tính nhất quán giữa các môi trường. Phạm vi không bao gồm việc huấn luyện mô hình ngôn ngữ từ đầu, mà sử dụng các mô hình có sẵn thông qua API (OpenAI, Gemini).

Chương 2 Cơ sở lý thuyết

2.1 Apache Kafka

Apache Kafka là một nền tảng xử lý luồng sự kiện phân tán được thiết kế để xử lý lưu lượng dữ liệu lớn với độ trễ thấp. Kafka hoạt động theo mô hình publish-subscribe, trong đó các producer gửi dữ liệu vào các topic, và các consumer đọc dữ liệu từ các topic này. Kafka được sử dụng rộng rãi nhờ khả năng mở rộng cao, độ bền vững và khả năng chịu lỗi.

Kiến trúc của Kafka bao gồm Producer (gửi dữ liệu), Broker (lưu trữ dữ liệu), Topic (danh mục logic), Partition (phân vùng để xử lý song song), và Consumer (đọc dữ liệu). Kafka sử dụng cơ chế offset để theo dõi vị trí đọc, đảm bảo consumer có thể đọc lại dữ liệu hoặc tiếp tục từ vị trí cũ khi xảy ra lỗi.

Trong đề tài này, Kafka làm hàng đợi tin nhắn giữa tầng thu thập và xử lý với ba topic: tiktok-raw, youtube-raw, và news-raw. Producer thu thập dữ liệu từ các nguồn và gửi vào topic tương ứng. Consumer đọc từ Kafka để xử lý qua pipeline phát hiện xu hướng.

2.2 Apache Spark

Apache Spark là framework xử lý dữ liệu lớn mã nguồn mở, hỗ trợ xử lý batch và streaming. PySpark là API Python của Spark. Ưu điểm lớn nhất của Spark là tốc độ xử lý nhờ in-memory computing thay vì đọc ghi đĩa như MapReduce. Spark cung cấp thư viện cho machine learning (MLlib), xử lý đồ thị (GraphX), và streaming.

Spark sử dụng kiến trúc master-worker với Driver Program (điều phối công việc), Cluster Manager (quản lý tài nguyên), và Executor (thực thi task). Spark sử dụng RDD (Resilient Distributed Dataset) - tập dữ liệu phân tán chịu lỗi, và cung cấp DataFrame/Dataset API với Catalyst Optimizer để tối ưu hiệu suất.

Trong đề tài này, PySpark xử lý batch dữ liệu từ Kafka. Consumer đọc từ ba topic, chuyển thành DataFrame, và xử lý qua pipeline tám giai đoạn. Spark xử lý hàng nghìn nội dung hiệu quả với xử lý song song. Hệ thống chạy local[*] để dùng tất cả core CPU.

2.3 Vector Embeddings

Vector embeddings là kỹ thuật biểu diễn văn bản dưới dạng vector số học trong không gian đa chiều (128-1536 chiều). Văn bản có ý nghĩa tương tự sẽ có vector gần nhau. Khoảng cách giữa hai vector (cosine similarity hoặc Euclidean distance) phản ánh mức độ tương đồng ngữ nghĩa.

Embeddings được tạo bởi các mô hình học sâu huấn luyện trên dữ liệu lớn, học cách nắm bắt ngữ nghĩa và ngữ cảnh. Ví dụ: "xe hơi" và "ô tô" có vector gần nhau vì cùng ý nghĩa, còn "xe hơi" và "máy bay" xa hơn dù cùng lĩnh vực giao thông.

Trong đề tài này, vector embeddings then chốt cho phân cụm và khử trùng. Hệ thống dùng OpenAI (text-embedding-3-small, 1536 chiều) hoặc Gemini để chuyển văn bản (nội dung + hashtags) thành vector. Vector này làm đầu vào cho HDBSCAN phân cụm nội dung tương đồng. Ở giai đoạn khử trùng, hệ thống tính cosine similarity giữa embedding xu hướng mới và cũ để quyết định có gộp hay không.


2.4 HDBSCAN

HDBSCAN (Hierarchical Density-Based Spatial Clustering of Applications with Noise) là thuật toán phân cụm dựa mật độ, cải tiến của DBSCAN. HDBSCAN phát hiện các cụm có mật độ khác nhau và tự động xác định số lượng cụm, khác k-means cần chỉ định trước.

Ưu điểm: (1) không cần chỉ định số cụm; (2) phát hiện cụm hình dạng bất kỳ; (3) xử lý tốt outliers (gán nhãn -1); (4) hoạt động với cụm mật độ khác nhau. Độ phức tạp $O(n \log n)$, cao hơn k-means nhưng chấp nhận được.

HDBSCAN hoạt động qua: (1) Xây đồ thị khoảng cách tối thiểu; (2) Tạo phân cấp cụm; (3) Trích xuất cụm ổn định; (4) Gán nhãn (cụm hoặc nhiễu -1). Tham số quan trọng là `min_cluster_size` (kích thước tối thiểu cụm).

Trong đề tài này, HDBSCAN phân cụm nội dung có embedding tương đồng thành xu hướng. Cấu hình: `min_cluster_size=15`, `metric="euclidean"`, `cluster_selection_method="eom`. Hệ thống dùng two-pass clustering: lần đầu phân cụm, lần hai gán điểm nhiễu vào cụm gần nhất để tránh bỏ sót nội dung tiềm năng.



Hình 2.1: Minh họa thuật toán HDBSCAN phân cụm dựa mật độ

2.5 Large Language Models

Large Language Models (LLM) là mô hình ngôn ngữ lớn huấn luyện trên dữ liệu văn bản khổng lồ, có khả năng hiểu và sinh văn bản tự nhiên. LLM dùng kiến trúc Transformer với hàng tỷ tham số, thực hiện nhiều tác vụ NLP như tóm tắt, phân tích cảm xúc, trích xuất thông tin, dịch máy.

LLM phổ biến: GPT-4 (OpenAI), Gemini (Google), Claude (Anthropic), Llama (mã nguồn mở). Ưu điểm là few-shot và zero-shot learning, chỉ cần mô tả tác vụ bằng ngôn ngữ tự nhiên (prompt engineering).

Trong đề tài này, LLM dùng cho: (1) Embedding - OpenAI text-embedding-3-small hoặc Gemini chuyển văn bản thành vector 1536 chiều cho phân cụm và khử trùng; (2) Phân tích xu hướng - GPT-4 hoặc Gemini phân tích từng cụm. Với mỗi cụm, hệ thống chọn top 10 nội dung engagement cao, xây prompt và yêu cầu LLM trích xuất: topic, summary, sentiment, keywords, content_type, risk_level, guidelines cho marketer/social manager. LLM cho phép phân tích tự động mà không cần rules thủ công.


Chương 3 Kết quả thực hiện

3.1 Kiến trúc tổng thể hệ thống

Hệ thống phát hiện xu hướng xã hội được xây dựng theo kiến trúc ba tầng: tầng thu thập dữ liệu (Producer), tầng xử lý phân tích (Consumer), và tầng giao diện người dùng (Dashboard). Luồng dữ liệu chạy một chiều từ các nguồn mạng xã hội, qua Apache Kafka message queue, đến pipeline xử lý PySpark, cuối cùng lưu vào MongoDB và hiển thị trên Streamlit dashboard.

Tầng Producer sử dụng các API và công cụ scraping để thu thập dữ liệu từ ba nguồn TikTok, YouTube và News, sau đó gửi vào ba Kafka topics tương ứng (tiktok-raw, youtube-raw, news-raw). Tầng Consumer đọc dữ liệu từ Kafka, xử lý qua pipeline tám giai đoạn sử dụng PySpark, và lưu kết quả vào MongoDB. Tầng Dashboard sử dụng Streamlit để cung cấp hai giao diện: user dashboard cho người dùng xem xu hướng và admin dashboard cho quản trị viên quản lý hệ thống.

Hệ thống hoạt động theo chế độ batch với chu kỳ bốn giờ một lần. Mỗi lần chạy, Producer thu thập khoảng 1500-2000 nội dung mới, Consumer xử lý và phát hiện các cụm xu hướng, sau đó cập nhật vào database. Dashboard tự động làm mới để hiển thị xu hướng mới nhất. Toàn bộ hệ thống được đóng gói bằng Docker để đảm bảo tính nhất quán giữa các môi trường.



Hình 3.1: Sơ đồ kiến trúc tổng thể hệ thống phát hiện xu hướng xã hội

3.2 Tầng thu thập dữ liệu (Producer)

3.2.1 Thu thập từ TikTok

Producer TikTok sử dụng Apify API để thu thập video từ các hashtag hoặc từ khóa đang theo dõi. Mỗi lần chạy, hệ thống lấy 100 video mới nhất cho mỗi từ khóa, tổng cộng khoảng 300-500 video tùy thuộc vào số lượng từ khóa active. Dữ liệu thu thập bao gồm: video ID, mô tả, hashtags, số lượt xem, lượt thích, bình luận, chia sẻ, tác giả, thời gian đăng, và URL video.

Để tối ưu chi phí API, hệ thống cấu hình Apify Actor với các tham số: maxProfilesPerQuery=100, shouldDownloadVideos=false (chỉ lấy metadata), resultsPerPage=30. Thời gian thu thập trung bình cho một batch TikTok là 2-3 phút. Dữ liệu sau khi thu thập được chuẩn hóa về schema thống nhất và gửi vào Kafka topic tiktok-raw.

3.2.2 Thu thập từ YouTube

Producer YouTube sử dụng YouTube Data API v3 để tìm kiếm video dựa trên từ khóa. Với mỗi từ khóa, hệ thống gọi API search.list với các tham số: part=snippet, type=video, maxResults=50, order=date để lấy 50 video mới nhất. Sau đó, hệ thống gọi videos.list để lấy thông kê chi tiết (lượt xem, lượt thích, bình luận) cho từng video.

Để không vượt quá quota giới hạn của YouTube API (10000 units/ngày), hệ thống tối ưu bằng cách: (1) kết hợp search.list và videos.list trong một batch request; (2) cache kết quả trong 4 giờ; (3) giới hạn tối đa 10 từ khóa active. Mỗi lần chạy thu thập khoảng 200-300 video. Thời gian thu thập trung bình là 1-2 phút. Dữ liệu được gửi vào Kafka topic youtube-raw.

3.2.3 Thu thập từ News

Producer News thu thập tin tức từ bốn nguồn trực tuyến Việt Nam (VNExpress, Tuổi Trẻ, VTC News, Thanh Niên) thông qua RSS feeds. Hệ thống sử dụng thư viện feedparser để parse RSS XML, lấy các bài báo mới nhất từ mỗi nguồn. Với mỗi nguồn, hệ thống lấy tối đa 50 bài mới nhất, tổng cộng khoảng 100-150 bài mỗi lần chạy.

Dữ liệu thu thập bao gồm: tiêu đề, mô tả, nội dung tóm tắt, thời gian đăng, tác giả, và URL bài báo. Vì RSS feeds thường không cung cấp số liệu tương tác (lượt xem, lượt thích), hệ thống sử dụng các chỉ số thay thế như độ dài nội dung và số lượng từ

khóa xuất hiện để đánh giá chất lượng. Thời gian thu thập trung bình là dưới 1 phút. Dữ liệu được gửi vào Kafka topic news-raw.

3.2.4 Kafka Producer

Sau khi thu thập và chuẩn hóa, dữ liệu từ ba nguồn được gửi vào Apache Kafka thông qua KafkaProducer. Hệ thống cấu hình Producer với các tham số: `acks='all'` để đảm bảo dữ liệu được ghi vào tất cả replica, `compression_type='gzip'` để giảm băng thông, `max_in_flight_requests_per_connection=5` để tối ưu throughput.

Mỗi message trong Kafka chứa một content item được serialize bằng JSON, bao gồm toàn bộ metadata và các chỉ số tương tác. Kafka topics được cấu hình với `replication_factor=1` (do chạy single-node), `num_partitions=1`, `retention.ms=86400000` (24 giờ). Hệ thống ghi log mỗi lần gửi thành công để theo dõi và debug. Tổng thời gian thu thập và gửi vào Kafka cho cả ba nguồn thường dưới 5 phút.

3.2.5 Keyword Extractor

Keyword Extractor là module hỗ trợ thu thập và đề xuất từ khóa trending mới từ tin tức một cách tự động. Khác với Producer chính chạy 4 giờ một lần và phụ thuộc vào danh sách từ khóa có sẵn, Keyword Extractor hoạt động độc lập, chạy một lần mỗi ngày để phát hiện từ khóa tiềm năng viral từ các tiêu đề báo mới.

Hệ thống sử dụng 23 RSS feeds từ các chuyên mục trending của bốn tờ báo lớn (VNExpress, Tuổi Trẻ, VTC News, Thanh Niên), tập trung vào các lĩnh vực có tiềm năng viral cao: giải trí, công nghệ, lifestyle, sức khỏe, xe, du lịch, thể thao. Các chuyên mục về chính trị, quân sự, kinh tế và pháp luật bị loại trừ vì ít phù hợp cho mục đích marketing.

Quy trình extraction gồm bốn bước: (1) Scraping - thu thập headlines từ 23 RSS feeds, giới hạn tối đa 1000 tiêu đề; (2) Batch Processing - tổng hợp tất cả headlines vào một prompt duy nhất; (3) LLM Analysis - sử dụng GPT-4o-mini hoặc Gemini Flash để phân tích và trích xuất 30 từ khóa có tiềm năng viral cao nhất, kèm theo category (giải trí/công nghệ/lifestyle/...) và reason (lý do trending); (4) Storage - lưu vào MongoDB collection `extracted_keywords` với status 'pending' để admin review.

Chi phí cho mỗi lần extraction rất thấp (~\$0.03-0.05 cho 800-1200 headlines trong một LLM call), so với việc chạy Producer với từ khóa không hiệu quả. Keyword Extractor giúp admin phát hiện xu hướng mới nhanh chóng mà không cần theo dõi tin tức thủ công. Admin có thể approve từ khóa với một click, từ khóa sẽ tự động được

thêm vào `active_keywords` và áp dụng cho tất cả Producer (TikTok, YouTube, News) trong chu kỳ tiếp theo.

3.3 Tầng xử lý phân tích (Consumer)

3.3.1 Kafka Consumer

Consumer đọc dữ liệu từ ba Kafka topics sử dụng `KafkaConsumer` với cấu hình: `group_id='trend-detector-consumer'`, `auto_offset_reset='earliest'`, `enable_auto_commit=False`. Hệ thống tắt auto-commit và sử dụng manual commit sau khi xử lý thành công để đảm bảo không mất dữ liệu khi xảy ra lỗi.

Mỗi lần chạy, Consumer poll dữ liệu từ cả ba topics, deserialize từ JSON, và tổng hợp thành một batch dữ liệu thống nhất. Hệ thống sử dụng cơ chế checkpoint: sau khi xử lý và lưu kết quả thành công, Consumer mới commit offset. Nếu xảy ra lỗi trong quá trình xử lý, Consumer sẽ đọc lại từ offset cũ trong lần chạy tiếp theo, đảm bảo exactly-once processing.

3.3.2 Pipeline xử lý 8 giai đoạn

Pipeline xử lý được triển khai bằng PySpark với `SparkSession` cấu hình `local[*]` để sử dụng tất cả CPU cores. Dữ liệu từ Consumer được chuyển thành Spark DataFrame và xử lý qua tám giai đoạn tuần tự.

Giai đoạn 1 - Normalization: Chuẩn hóa schema từ ba nguồn khác nhau về cấu trúc thống nhất với các trường: `content_id`, `title`, `description`, `content`, `author`, `views`, `likes`, `comments`, `shares`, `hashtags`, `source`, `timestamp`. Hệ thống xử lý các trường bị thiếu, chuyển đổi kiểu dữ liệu, và tạo trường `text_for_embedding` bằng cách kết hợp `title`, `description` và `hashtags`.

Giai đoạn 2 - Cleaning: Làm sạch dữ liệu bằng cách: loại bỏ HTML tags, xóa URLs và mentions, chuẩn hóa khoảng trắng, loại bỏ ký tự đặc biệt, và kiểm tra tính hợp lệ của các trường bắt buộc. Các item không hợp lệ (thiếu title hoặc description, text quá ngắn <20 ký tự) bị loại bỏ. Tỷ lệ item bị loại ở giai đoạn này thường dưới 5%.

Giai đoạn 3 - Quality Filtering: Lọc spam và bot content dựa trên các chỉ số chất lượng. Tiêu chí lọc bao gồm: `engagement_rate` (`views > 0` và `likes/views >= 0.01`), `min_followers` (`author_followers >= 1000`), `text_quality` (độ dài `>= 50` ký tự, không chứa quá nhiều hashtags). Các item không đạt tiêu chí bị loại bỏ. Giai đoạn này loại

bỏ khoảng 20-30% items, giữ lại những nội dung có chất lượng và tương tác thực.

Giai đoạn 4 - Embedding Generation: Chuyển đổi văn bản thành vector embeddings 1536 chiều. Hệ thống hỗ trợ hai provider: OpenAI (text-embedding-3-small) hoặc Gemini (text-embedding-004). Với mỗi item, hệ thống gửi trường text_for_embedding đến API và nhận về vector 1536 chiều. Để tối ưu chi phí, hệ thống: (1) batch multiple items trong một request (25 items/batch cho OpenAI, 100 items/batch cho Gemini); (2) implement retry với exponential backoff cho rate limit; (3) cache embeddings trong database để tránh tính toán lại. Thời gian trung bình cho giai đoạn này là 3-5 phút cho 1500 items.

Giai đoạn 5 - Clustering: Phân cụm nội dung tương đồng bằng thuật toán HDBSCAN. Hệ thống cấu hình: min_cluster_size=15 (cụm tối thiểu 15 items), metric='euclidean', cluster_selection_method='eom' (Excess of Mass). HDBSCAN tự động xác định số lượng cụm dựa trên mật độ, không cần chỉ định trước. Các item không thuộc cụm nào được gán nhãn -1 (noise).

Để giảm thiểu noise, hệ thống áp dụng two-pass clustering: lần đầu phân cụm, lần hai gán các điểm noise vào cụm gần nhất nếu khoảng cách nhỏ hơn ngưỡng (threshold=0.5). Kết quả thường phát hiện 5-15 cụm mỗi batch, với kích thước cụm từ 15 đến 100+ items. Cụm lớn thường là xu hướng có phạm vi rộng, cụm nhỏ là xu hướng niche.

Giai đoạn 6 - Trend Analysis: Phân tích từng cụm bằng Large Language Model để trích xuất thông tin xu hướng. Với mỗi cụm, hệ thống: (1) chọn top 10 items có engagement cao nhất; (2) xây dựng prompt chứa title, description và stats của 10 items này; (3) gọi GPT-4 hoặc Gemini để phân tích và trích xuất: topic (chủ đề chính), summary (tóm tắt xu hướng), sentiment (tích cực/tiêu cực/trung lập), keywords (5-10 từ khóa), content_type (giải trí/drama/nguy hiểm/vấn đề xã hội/thương mại), risk_level (an toàn/thận trọng/rủi ro cao/nguy hiểm), guidelines (hướng dẫn cho marketer và social media manager).

Prompt được thiết kế để yêu cầu LLM trả về JSON có cấu trúc, đảm bảo dễ parse. Hệ thống validate response và retry nếu format không đúng. Với mỗi cụm, LLM analysis mất khoảng 5-10 giây. Thời gian cho giai đoạn này phụ thuộc vào số lượng cụm (5-15 cụm = 30-150 giây).


Giai đoạn 7 - Deduplication: Khử trùng với các xu hướng đã có trong database để tránh tạo xu hướng trùng lặp. Hệ thống sử dụng chiến lược đa yếu tố: (1) Embedding Similarity - tính cosine similarity giữa embedding trung bình của trend mới và trend

cũ, ngưỡng 0.75; (2) Keyword Overlap - tính tỷ lệ keywords trùng nhau, ngưỡng 0.6; (3) Source Distribution - so sánh phân bố nguồn (TikTok/YouTube/News), cho phép chênh lệch tối đa 30%.

Nếu trend mới match với trend cũ ($\text{similarity} \geq 0.75$ và $\text{keyword_overlap} \geq 0.6$), hệ thống sẽ merge: cập nhật sample items, cộng dồn stats, và refresh timestamp. Nếu không match, trend mới được tạo. Cơ chế này đảm bảo database không bị duplicate và các trend được cập nhật liên tục với nội dung mới.

Giai đoạn 8 - Storage & Timeout: Lưu xu hướng vào MongoDB collection 'trends' và tự động dọn dẹp xu hướng cũ. Mỗi trend document chứa: trend_id, topic, summary, sentiment, keywords, content_type, risk_level, guidelines, sample_videos (top 5 items), stats (total_views, total_likes, avg_engagement), source_counts, created_at, updated_at.

Hệ thống implement timeout mechanism: trước khi lưu trends mới, tự động xóa các trends có updated_at > 3 ngày. Điều này đảm bảo database luôn chứa xu hướng mới nhất và không bị phình to theo thời gian. Ngoài trends collection, hệ thống còn lưu các collections khác: user_submissions (đề xuất từ khóa từ user), active_keywords (từ khóa đang theo dõi), keyword_history (lịch sử thay đổi keyword).



Hình 3.2: Sơ đồ chi tiết pipeline xử lý 8 giai đoạn

3.3.3 Cơ chế xử lý lỗi

Hệ thống triển khai nhiều lớp xử lý lỗi để đảm bảo tính ổn định. Ở tầng Producer, nếu API call thất bại, hệ thống retry tối đa 3 lần với exponential backoff (1s, 2s, 4s). Nếu vẫn thất bại, skip source đó và tiếp tục các source khác. Ở tầng Consumer, nếu embedding API hoặc LLM API gặp rate limit, hệ thống tự động chờ và retry. Nếu xảy ra lỗi nghiêm trọng (crash, exception), Consumer không commit offset, đảm bảo dữ liệu sẽ được xử lý lại trong lần chạy tiếp theo.

Hệ thống ghi log chi tiết ở mọi giai đoạn, bao gồm: số lượng items ở mỗi stage, số lượng items bị loại bỏ, số cụm phát hiện, số trends mới/merged, và thời gian xử lý. Logs được lưu vào file và có thể xem qua Docker logs. Ngoài ra, hệ thống có health check endpoint để monitoring.


3.4 Tầng giao diện (Dashboard)

3.4.1 User Dashboard

User Dashboard được xây dựng bằng Streamlit, cung cấp giao diện web để người dùng xem và tìm kiếm xu hướng. Dashboard hiển thị danh sách xu hướng được sắp xếp theo tổng engagement (views + likes) giảm dần, đảm bảo xu hướng hot nhất xuất hiện đầu tiên.

Mỗi trend card hiển thị đầy đủ thông tin: topic (tiêu đề lớn), summary (tóm tắt nội dung), sentiment với màu sắc tương ứng (xanh lá - tích cực, đỏ - tiêu cực, xám - trung lập), risk_level với icon cảnh báo, content_type, keywords dạng tags, total stats (tổng views, likes, engagement rate), source distribution (biểu đồ phần trăm TikTok/YouTube/News), và top 5 sample videos với link trực tiếp.

Dashboard cung cấp các chức năng filter và search: (1) Text search - tìm kiếm theo topic hoặc keywords; (2) Sentiment filter - lọc theo cảm xúc (all/positive/negative/neutral); (3) Content type filter - lọc theo loại nội dung; (4) Risk level filter - lọc theo mức độ rủi ro. Bên cạnh đó, user có thể đề xuất từ khóa mới qua form, submission sẽ được lưu vào database với status 'pending' chờ admin duyệt.



Hình 3.3: Giao diện User Dashboard hiển thị xu hướng và chức năng tìm kiếm

3.4.2 Admin Dashboard


Admin Dashboard cung cấp các chức năng quản trị hệ thống. Giao diện chia thành ba tabs: Quản lý xu hướng, Đề xuất từ khóa, và Từ khóa hoạt động.

Quản lý xu hướng: Admin có thể xem tất cả trends với đầy đủ thông tin, tìm kiếm theo topic, và xóa trends không mong muốn. Mỗi trend hiển thị thêm thông tin kỹ thuật như trend_id, created_at, updated_at. Chức năng xóa có confirmation để tránh xóa nhầm.

Đề xuất từ khóa: Tab này chia làm hai cột để quản lý từ khóa từ hai nguồn khác nhau. Cột trái hiển thị đề xuất từ người dùng (user submissions) với thông tin keyword, reason, submitted_by, status. Admin có thể approve hoặc reject từng submission. Cột phải hiển thị từ khóa được Keyword Extractor tự động trích xuất từ tin tức, bao gồm keyword, category (giải trí/công nghệ/...), reason (lý do trending), status. Mỗi extracted keyword có button "Thêm vào keywords" để approve và tự động thêm vào active_keywords áp dụng cho tất cả nguồn, hoặc "Bỏ qua" để reject. Cả hai nguồn đều có filter theo status (pending/approved/rejected/all) để dễ quản lý.

Từ khóa hoạt động: Hiển thị danh sách active_keywords hiện tại với các chức năng: (1) Thêm keyword mới thủ công qua form; (2) Sửa keyword hiện có - khi click "Sửa", keyword chuyển thành input field với buttons "Lưu"/"Hủy", cho phép admin chỉnh sửa nhanh; (3) Xóa keyword không còn cần thiết. Tất cả thay đổi được ghi log

vào keyword_history collection để audit: action (add/update/remove/approve), keyword, performed_by, timestamp, details (old_keyword, new_keyword). Mỗi keyword áp dụng cho tất cả ba nguồn TikTok, YouTube và News.



Hình 3.4: Giao diện Admin Dashboard với các chức năng quản trị hệ thống

Chương 4 Kết luận

Đồ án đã xây dựng thành công một hệ thống phát hiện xu hướng xã hội hoàn chỉnh, có khả năng tự động thu thập, xử lý và phân tích dữ liệu từ nhiều nền tảng mạng xã hội. Hệ thống kết hợp kiến trúc ba tầng (Producer - Consumer - Dashboard) với các công nghệ hiện đại như Apache Kafka, PySpark, HDBSCAN, và Large Language Models để tạo ra một giải pháp tích hợp và tự động hóa cao.

4.1 Kết quả đạt được

Về mặt kỹ thuật, hệ thống đã triển khai thành công pipeline xử lý tám giai đoạn với khả năng xử lý 1500-2000 nội dung mỗi lần chạy trong khoảng 10-15 phút. Tầng thu thập dữ liệu hoạt động ổn định với ba nguồn TikTok, YouTube và News, sử dụng các API và RSS feeds để lấy dữ liệu mới nhất. Apache Kafka đóng vai trò message queue trung gian, đảm bảo tính ổn định và khả năng mở rộng của hệ thống.

Pipeline xử lý sử dụng PySpark đã tích hợp thành công các kỹ thuật học máy và xử lý ngôn ngữ tự nhiên. Giai đoạn embedding chuyển đổi văn bản thành vector 1536 chiều, cho phép so sánh ngữ nghĩa chính xác. Thuật toán HDBSCAN với cấu hình `min_cluster_size=15` tự động phát hiện 5-15 cụm xu hướng mỗi batch mà không cần chỉ định trước số lượng cụm. Đặc biệt, việc tích hợp Large Language Models (GPT-4, Gemini) cho phép phân tích tự động và trích xuất thông tin chuyên sâu cho từng xu hướng, bao gồm chủ đề, tóm tắt, cảm xúc, từ khóa, loại nội dung, mức độ rủi ro và hướng dẫn sử dụng.

Cơ chế khử trùng đa yếu tố (embedding similarity, keyword overlap, source distribution) với ngưỡng 0.75 hoạt động hiệu quả, đảm bảo database không bị duplicate và các xu hướng được cập nhật liên tục. Timeout mechanism tự động xóa xu hướng cũ hơn 3 ngày giúp duy trì độ tươi mới của dữ liệu. Checkpoint mechanism ở Consumer đảm bảo exactly-once processing, không bị mất dữ liệu khi xảy ra lỗi.

Về giao diện người dùng, hai dashboard Streamlit cung cấp trải nghiệm tốt cho cả người dùng cuối và quản trị viên. User dashboard hiển thị xu hướng với đầy đủ thông tin, chức năng tìm kiếm và lọc linh hoạt, cùng form đề xuất từ khóa. Admin dashboard cho phép quản lý xu hướng, duyệt đề xuất từ khóa, và theo dõi lịch sử thay đổi. Giao diện trực quan, dễ sử dụng, không yêu cầu kiến thức kỹ thuật.

4.2 Hạn chế và thách thức

Bất chấp những kết quả đạt được, hệ thống còn một số hạn chế cần khắc phục trong tương lai. Hạn chế lớn nhất là chưa hỗ trợ xử lý streaming thời gian thực hoàn toàn. Hệ thống hiện hoạt động theo chế độ batch với chu kỳ bốn giờ, dẫn đến độ trễ trong việc phát hiện xu hướng mới nổi. Mặc dù độ trễ này chấp nhận được cho hầu hết use cases, nhưng với các xu hướng viral nhanh, hệ thống có thể bỏ lỡ giai đoạn bùng nổ ban đầu.

Về phạm vi dữ liệu, hệ thống chỉ tập trung vào ba nền tảng TikTok, YouTube và News, chưa bao gồm các nền tảng lớn khác như Facebook, Instagram, Twitter/X. Điều này hạn chế khả năng phát hiện xu hướng đa nền tảng toàn diện. Nguyên nhân chính là hạn chế về thời gian và khả năng truy cập API của các nền tảng này (Facebook và Instagram có API rất hạn chế, Twitter/X tính phí cao).

Chi phí vận hành là một thách thức đáng kể. Hệ thống phụ thuộc vào các API trả phí như OpenAI (embedding và analysis), Apify (TikTok), và YouTube Data API. Với mỗi batch 1500 items, chi phí embedding khoảng \$0.10-0.15 và chi phí LLM analysis khoảng \$0.50-1.00 (tùy số lượng cụm). Chạy mỗi 4 giờ (6 lần/ngày) dẫn đến chi phí hàng tháng khoảng \$100-150, chưa tính chi phí Apify. Điều này có thể là rào cản cho việc triển khai rộng rãi hoặc sử dụng cá nhân.

Về mặt kỹ thuật, quality filtering hiện chỉ dựa trên các chỉ số đơn giản như engagement rate và số followers, chưa phát hiện tốt các loại spam phức tạp hoặc bot tinh vi. HDBSCAN đôi khi tạo ra các cụm quá lớn hoặc quá nhỏ, đặc biệt khi dữ liệu có mật độ không đồng đều. Two-pass clustering đã cải thiện phần nào nhưng vẫn còn khoảng 10-15% items bị gán nhãn noise không chính xác.

LLM analysis đôi khi không nhất quán, đặc biệt với các xu hướng mơ hồ hoặc có nhiều khía cạnh. Hệ thống phụ thuộc hoàn toàn vào chất lượng response từ LLM, và việc validate JSON output không đảm bảo semantic correctness. Ngoài ra, prompt engineering cần điều chỉnh liên tục để cải thiện chất lượng analysis.

4.3 Đánh giá chung

Nhìn chung, đồ án đã đạt được mục tiêu ban đầu: xây dựng một hệ thống tự động phát hiện và phân tích xu hướng xã hội từ nhiều nguồn. Kiến trúc ba tầng với Kafka làm message queue và PySpark làm processing engine tạo ra một nền tảng vững chắc, có khả năng mở rộng. Việc kết hợp HDBSCAN cho clustering và LLM cho analysis là

một approach hiệu quả, tận dụng được ưu điểm của cả machine learning truyền thống và mô hình ngôn ngữ lớn hiện đại.

Hệ thống đã chứng minh khả năng hoạt động trong thực tế, có thể phát hiện các xu hướng thực tế từ dữ liệu mạng xã hội Việt Nam. Dashboard cung cấp giá trị thực tiễn cho các nhà tiếp thị và quản lý mạng xã hội. Những hạn chế hiện tại chủ yếu liên quan đến quy mô và chi phí, có thể được khắc phục trong các phiên bản tiếp theo.

Đồ án không chỉ là một sản phẩm phần mềm hoàn chỉnh mà còn là minh chứng cho khả năng tích hợp nhiều công nghệ tiên tiến vào một hệ thống thống nhất. Kiến thức và kinh nghiệm thu được từ đồ án về xử lý dữ liệu lớn, phân cụm mật độ, embedding vectors, và prompt engineering sẽ là nền tảng vững chắc cho các dự án tương lai.

Chương 5 Hướng phát triển

Dựa trên kết quả và hạn chế hiện tại, đồ án có thể được mở rộng và cải tiến theo các hướng sau:

Xử lý streaming thời gian thực: Chuyển từ batch processing sang streaming architecture sử dụng Spark Structured Streaming hoặc Apache Flink. Điều này cho phép phát hiện xu hướng với độ trễ chỉ vài phút thay vì bốn giờ, đặc biệt quan trọng với các xu hướng viral nhanh. Cần thiết kế lại pipeline để xử lý incremental updates và maintain state cho clustering.

Mở rộng nguồn dữ liệu: Tích hợp thêm các nền tảng mạng xã hội lớn như Facebook, Instagram, Twitter/X, và các nền tảng Việt Nam như Zalo, Threads. Mỗi nền tảng có đặc thù riêng về API và loại nội dung, yêu cầu adapter pattern linh hoạt. Ngoài ra, có thể mở rộng sang các nguồn dữ liệu khác như podcast, forum, e-commerce reviews.

Tối ưu chi phí: Giảm phụ thuộc vào API trả phí bằng cách: (1) self-host embedding models như sentence-transformers hoặc Gemma; (2) sử dụng mô hình ngôn ngữ lớn mã nguồn mở như Llama 3 hoặc Qwen cho analysis; (3) implement caching thông minh để tránh tính toán lại. Trade-off là cần đầu tư infrastructure (GPU) nhưng chi phí dài hạn thấp hơn.

Cải thiện quality filtering: Áp dụng các kỹ thuật machine learning để phát hiện spam và bot phức tạp hơn. Huấn luyện classifier dựa trên features như writing patterns, posting frequency, account age. Tích hợp sentiment analysis để lọc nội dung tiêu cực hoặc toxic trước khi phân cụm.

Dự đoán xu hướng: Xây dựng mô hình time-series forecasting để dự đoán xu hướng sắp bùng nổ dựa trên tốc độ tăng trưởng engagement, pattern lan truyền, và historical data. Sử dụng kỹ thuật như LSTM, Prophet, hoặc Transformer-based models. Điều này cho phép doanh nghiệp chuẩn bị chiến lược proactive thay vì reactive.

Personalization: Xây dựng hệ thống recommendation cá nhân hóa, gợi ý xu hướng phù hợp với từng user dựa trên industry, interests, past interactions. Áp dụng collaborative filtering hoặc content-based filtering kết hợp với embedding similarity.

Hỗ trợ đa ngôn ngữ: Mở rộng sang các ngôn ngữ khác ngoài tiếng Việt và tiếng Anh. Sử dụng multilingual embeddings như mBERT hoặc XLM-RoBERTa để xử lý nhiều ngôn ngữ trong cùng một không gian vector, cho phép phát hiện xu hướng

cross-language.

Visual content analysis: Tích hợp xử lý hình ảnh và video để phân tích visual trends. Sử dụng CLIP hoặc các mô hình multimodal để extract embeddings từ thumb-nail, video frames, kết hợp với text embeddings để có phân tích toàn diện hơn.

Monitoring và alerting: Xây dựng hệ thống monitoring chi tiết với metrics (processing time, API costs, cluster quality), dashboards cho admin, và alerting khi phát hiện anomalies hoặc xu hướng rủi ro cao. Tích hợp với Prometheus, Grafana hoặc các công cụ APM.

API và integration: Cung cấp RESTful API hoặc GraphQL endpoint cho phép các ứng dụng bên ngoài tích hợp dữ liệu xu hướng. Xây dựng webhook để notify real-time khi phát hiện xu hướng mới. Điều này mở ra khả năng commercialize hệ thống như một trend detection service.

Tài liệu tham khảo