

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA CÔNG NGHỆ PHẦN MỀM

PHÁT HIỆN XU HƯỚNG XÃ HỘI THEO THỜI GIAN THỰC

LỚP: SE363.Q11

GV HƯỚNG DẪN:

TS. Đỗ Trọng Hợp

NHÓM 7:

Quách Gia Kiệt - 23520819

Phạm Thành Long - 23520887

Huỳnh Trần Anh Thư - 23521535

TP. HỒ CHÍ MINH, 2025

LỜI CẢM ƠN

Nhóm chúng em xin gửi lời cảm ơn và lòng biết ơn sâu sắc nhất tới thầy Đỗ Trọng Hợp, giảng viên hướng dẫn cho nhóm. Thầy đã luôn nhiệt tình, đồng hành, hỗ trợ và giúp đỡ chúng em trong suốt quá trình thực hiện đồ án môn học

Trong thời gian một học kỳ thực hiện đề tài, nhóm chúng em đã vận dụng những kiến thức nền tảng đã tích lũy đồng thời kết hợp với việc học hỏi và nghiên cứu những kiến thức mới, và đặc biệt là những kiến thức từ lý thuyết đến thực hành mà thầy đã nhiệt huyết giảng dạy cho chúng em. Từ đó, nhóm chúng em vận dụng tối đa những gì đã thu thập được để hoàn thành một báo cáo đồ án tốt nhất.

Trong quá trình thực hiện đồ án này, với kinh nghiệm và thời gian có hạn, nhóm không tránh khỏi được sai sót, chúng em kính mong nhận được sự góp ý, hướng dẫn của thầy để có thể hoàn thiện đồ án hơn nữa, cũng như là hành trang để nhóm chúng em thực hiện tiếp các đề tài khác trong tương lai.

Nhóm em xin chân thành cảm ơn thầy!

Nhóm sinh viên thực hiện
Quách Gia Kiệt
Phạm Thành Long
Huỳnh Trần Anh Thư

Mục lục

Lời cảm ơn	1
Tóm tắt đồ án	1
1 Mở đầu	4
1.1 Lý do chọn đề tài	4
1.2 Mục đích	4
1.3 Đối tượng nghiên cứu	5
1.4 Phạm vi nghiên cứu	5
2 Công trình liên quan	7
2.1 Các hệ thống phát hiện xu hướng hiện có	7
2.1.1 Google Trends	7
2.1.2 TikTok Creative Center	7
2.1.3 YouTube Trending	8
2.2 Các phương pháp xử lý dữ liệu lớn và phân cụm	8
2.2.1 MapReduce và Hadoop	8
2.2.2 Apache Spark	8
2.2.3 Thuật toán phân cụm	9
2.3 Các phương pháp phân tích ngôn ngữ tự nhiên	9
2.3.1 TF-IDF và BOW	9
2.3.2 Word2Vec và FastText	10
2.3.3 Sentence Transformers và OpenAI Embeddings	10
2.3.4 Large Language Models (LLM)	10
2.4 Khoảng trống nghiên cứu và đóng góp của đề tài	11
3 Phương pháp đề xuất	13
3.1 Kiến trúc tổng thể hệ thống	13
3.2 Pipeline xử lý tám giai đoạn	15

3.2.1	Giai đoạn 1: Chuẩn hóa (Normalization)	15
3.2.2	Giai đoạn 2: Làm sạch (Cleaning)	15
3.2.3	Giai đoạn 3: Lọc chất lượng (Filtering)	16
3.2.4	Giai đoạn 4: Chuyển đổi vector (Embedding)	16
3.2.5	Giai đoạn 5: Phân cụm (Clustering)	16
3.2.6	Giai đoạn 6: Phân tích (Analysis)	16
3.2.7	Giai đoạn 7: Gộp xu hướng (Deduplication)	17
3.2.8	Giai đoạn 8: Lưu trữ (Storage)	17
3.3	Các công nghệ chính	20
3.3.1	Apache Kafka	20
3.3.2	Apache Spark	20
3.3.3	Vector Embeddings	20
3.3.4	HDBSCAN	20
3.3.5	Large Language Models	21
3.4	Tham số và giả định	21
3.4.1	Tham số chính	21
3.4.2	Giả định	21
4	Thực nghiệm và Kết quả	22
4.1	Thiết lập thực nghiệm	22
4.1.1	Dữ liệu đầu vào	22
4.2	Chỉ số đánh giá	22
4.2.1	Chỉ số chất lượng phân cụm	22
4.2.2	Chỉ số Gộp xu hướng	23
4.2.3	Chỉ số phân loại	23
4.2.4	Chỉ số nguồn dữ liệu	23
4.3	Kết quả	23
4.3.1	Kết quả clustering	23
4.3.2	Kết quả Gộp xu hướng	24
4.3.3	Kết quả phân tích sentiment	24
4.3.4	Kết quả phân tích mức độ rủi ro	25
4.3.5	Kết quả phân loại nội dung	25
4.3.6	Kết quả phân bố nguồn dữ liệu	26
4.3.7	Phân bố source trong từng trend	26

4.4	So sánh với các phương pháp	27
4.4.1	So sánh với Google Trends	27
4.4.2	So sánh với TikTok Creative Center	27
5	Kết luận và Hướng phát triển	28
5.1	Kết quả đạt được	28
5.2	Hạn chế và thách thức	29
5.3	Đánh giá chung	30
5.4	Hướng phát triển	30
	Tài liệu tham khảo	32

TÓM TẮT ĐỒ ÁN

Vấn đề nghiên cứu

Trong bối cảnh mạng xã hội phát triển mạnh mẽ với hơn 5 tỷ người dùng toàn cầu, việc theo dõi và phát hiện các xu hướng đang nổi lên trở nên vô cùng quan trọng đối với các nhà tiếp thị, quản lý mạng xã hội và doanh nghiệp. Mỗi ngày, hàng triệu nội dung mới được tạo ra trên các nền tảng như TikTok, YouTube và các trang tin tức, tạo nên một khối lượng dữ liệu khổng lồ. Trong đó ẩn chứa các xu hướng - những chủ đề, sự kiện hoặc hiện tượng đang thu hút sự quan tâm đặc biệt của cộng đồng. Việc phát hiện và phân tích các xu hướng này sớm giúp doanh nghiệp điều chỉnh chiến lược marketing kịp thời, nhà báo nắm bắt các vấn đề xã hội nổi cộm, và quản lý mạng xã hội kiểm soát nội dung tiêu cực.

Tuy nhiên, việc theo dõi xu hướng từ nhiều nền tảng khác nhau hiện nay vẫn là một thách thức lớn. Hầu hết các công cụ hiện có chỉ tập trung vào một nền tảng duy nhất hoặc cung cấp dữ liệu thống kê đơn thuần mà không có phân tích chuyên sâu. Các phương pháp thủ công yêu cầu người dùng phải liên tục kiểm tra từng nền tảng, tốn thời gian và dễ bỏ sót thông tin quan trọng. Đặc biệt, việc tổng hợp và phân tích xu hướng đa nền tảng - khi một chủ đề xuất hiện đồng thời trên nhiều kênh - đòi hỏi kỹ năng và công sức vượt quá khả năng của hầu hết người dùng và tổ chức.

Cách giải quyết vấn đề

Để giải quyết vấn đề trên, đồ án xây dựng một hệ thống phát hiện xu hướng xã hội theo thời gian thực sử dụng kiến trúc kết hợp ba tầng chính: thu thập dữ liệu, xử lý phân tích, và giao diện người dùng.

Tầng thu thập dữ liệu sử dụng các API và công cụ scraping để tự động lấy nội dung từ ba nguồn chính: TikTok (qua Apify API), YouTube (qua YouTube Data API v3), và các trang tin tức trực tuyến Việt Nam (qua RSS feeds). Dữ liệu được gửi vào Apache Kafka - một hàng đợi tin nhắn phân tán đảm bảo tính ổn định và khả năng mở rộng.

Tầng xử lý phân tích sử dụng PySpark để xử lý batch dữ liệu qua pipeline tám giai đoạn: (1) chuẩn hóa dữ liệu từ các nguồn khác nhau về schema thống nhất; (2) làm sạch và kiểm tra tính hợp lệ; (3) lọc chất lượng để loại bỏ spam, bot dựa trên các chỉ số như tỷ lệ tương tác tối thiểu 1%, số người theo dõi tối thiểu 1000; (4) chuyển đổi văn bản thành vector embedding 1536 chiều bằng OpenAI hoặc Gemini; (5) phân cụm nội dung tương đồng bằng thuật toán HDBSCAN với kích thước cụm tối thiểu 15 items; (6) phân tích từng cụm bằng mô hình ngôn ngữ lớn (LLM) để trích xuất chủ đề, tóm tắt, phân tích cảm xúc, đánh giá rủi ro và tạo hướng dẫn sử dụng; (7) Gộp xu hướng với các xu hướng đã có sử dụng chiến lược đa yếu tố (embedding similarity, keyword overlap, source distribution) với ngưỡng 0.75; (8) lưu trữ vào MongoDB và tự động xóa xu hướng cũ hơn 3 ngày.

Tầng giao diện người dùng được xây dựng bằng Streamlit, cung cấp hai dashboard: dashboard người dùng để xem xu hướng với đầy đủ thông tin phân tích, và dashboard quản trị để quản lý xu hướng, duyệt đề xuất từ khóa từ người dùng. Toàn bộ hệ thống được đóng gói bằng Docker để dễ dàng triển khai và vận hành.

Kết quả đạt được

Đồ án đã xây dựng thành công một hệ thống phát hiện xu hướng xã hội hoàn chỉnh có khả năng tự động vận hành mỗi bốn giờ mà không cần can thiệp thủ công. Hệ thống có thể xử lý khoảng 1500-2000 nội dung mỗi lần chạy từ ba nguồn TikTok, YouTube và News, phát hiện các cụm xu hướng, và cung cấp phân tích chuyên sâu cho từng xu hướng.

Dashboard người dùng hiển thị các xu hướng được sắp xếp theo mức độ tương tác (lượt xem và lượt thích), với đầy đủ thông tin như chủ đề, tóm tắt, cảm xúc (tích cực/tiêu cực/trung lập), mức độ rủi ro (an toàn/thận trọng/rủi ro cao/nguy hiểm), loại nội dung (giải trí/drama/nguy hiểm/vấn đề xã hội/thương mại), và phân bố nguồn. Đặc biệt, hệ thống tự động tạo ra các hướng dẫn cụ thể cho marketer và quản lý mạng xã hội về cơ hội và rủi ro khi tham gia vào từng xu hướng. Dashboard quản trị cho phép quản lý xu hướng, duyệt và phê duyệt từ khóa đề xuất từ người dùng, và theo dõi lịch sử thay đổi từ khóa.

Hệ thống đã được triển khai thành công với Docker, đảm bảo tính nhất quán giữa các môi trường phát triển và production. Cơ chế checkpoint của consumer đảm bảo không bị mất dữ liệu khi xử lý thất bại, và cơ chế timeout tự động dọn dẹp xu hướng

cũ giúp database luôn chứa thông tin mới nhất. Tuy nhiên, hệ thống còn một số hạn chế như chưa hỗ trợ xử lý streaming thời gian thực hoàn toàn, chỉ tập trung vào ba nền tảng chính, và cần tối ưu hóa thêm về chi phí API LLM.

Bất chấp những hạn chế này, kết quả đạt được chứng minh rằng kiến trúc tích hợp Kafka, PySpark, HDBSCAN và LLM có khả năng hoạt động hiệu quả trong việc xây dựng hệ thống phát hiện xu hướng đa nền tảng. Đề án mở ra các cơ hội để mở rộng sang các nền tảng khác như Facebook, Twitter/X, tích hợp xử lý streaming thời gian thực, và áp dụng các kỹ thuật học sâu tiên tiến hơn cho dự đoán xu hướng trong tương lai.

Chương 1 Mở đầu

1.1 Lý do chọn đề tài

Trong kỷ nguyên số hiện nay, mạng xã hội đã trở thành một phần không thể thiếu trong cuộc sống của hàng tỷ người trên toàn thế giới. Theo thống kê của DataReportal năm 2024, có hơn 5 tỷ người dùng mạng xã hội toàn cầu, chiếm khoảng 62% dân số thế giới. Tại Việt Nam, con số này còn cao hơn với hơn 77 triệu người dùng, chiếm 76.9% dân số. Mỗi ngày, hàng triệu nội dung mới được tạo ra trên các nền tảng như TikTok, YouTube và các trang tin tức, tạo nên một khối lượng dữ liệu khổng lồ.

Trong khối lượng dữ liệu này ẩn chứa các xu hướng - những chủ đề, sự kiện hoặc hiện tượng đang thu hút sự quan tâm đặc biệt của cộng đồng trong một khoảng thời gian nhất định. Việc phát hiện và phân tích các xu hướng sớm mang lại nhiều lợi ích: doanh nghiệp có thể điều chỉnh chiến lược marketing kịp thời, nhà báo có thể nắm bắt các vấn đề xã hội đang nổi cộm, và các nhà quản lý mạng xã hội có thể kiểm soát nội dung tiêu cực trước khi lan rộng.

Tuy nhiên, việc theo dõi xu hướng từ nhiều nền tảng khác nhau hiện nay vẫn là một thách thức lớn. Hầu hết các công cụ hiện có như Google Trends, TikTok Creative Center chỉ tập trung vào một nền tảng duy nhất hoặc cung cấp dữ liệu thống kê đơn thuần mà không có phân tích chuyên sâu. Các phương pháp thủ công yêu cầu người dùng phải liên tục kiểm tra từng nền tảng, tốn thời gian và dễ bỏ sót thông tin quan trọng. Đặc biệt, việc tổng hợp và phân tích xu hướng đa nền tảng - khi một chủ đề xuất hiện đồng thời trên nhiều kênh - đòi hỏi kỹ năng và công sức vượt quá khả năng của hầu hết người dùng và tổ chức.

Nhận thấy vấn đề này, nhóm thực hiện quyết định xây dựng một hệ thống phát hiện xu hướng xã hội theo thời gian thực có khả năng tự động thu thập, xử lý và phân tích dữ liệu từ nhiều nguồn mạng xã hội, từ đó phát hiện các xu hướng đang nổi lên và cung cấp phân tích chuyên sâu một cách kịp thời và chính xác.

1.2 Mục đích

Đồ án có mục đích xây dựng một hệ thống hoàn chỉnh có khả năng tự động phát hiện và phân tích xu hướng trên các nền tảng mạng xã hội phổ biến tại Việt Nam. Cụ thể, hệ thống sẽ thu thập dữ liệu từ ba nguồn chính (TikTok, YouTube, và các trang tin

tức trực tuyến), xử lý và phân cụm nội dung tương đồng bằng các thuật toán học máy, sau đó phân tích chuyên sâu về chủ đề, cảm xúc, mức độ rủi ro và cung cấp khuyến nghị cụ thể cho người dùng.

Bên cạnh đó, đồ án cũng nhằm chứng minh khả năng tích hợp và ứng dụng thực tế các công nghệ hiện đại trong xử lý dữ liệu lớn và phân tích thông minh. Hệ thống kết hợp Apache Kafka cho message queue, PySpark cho xử lý batch, thuật toán HDBSCAN cho phân cụm mật độ, và các mô hình ngôn ngữ lớn (gpt-4.1-mini, Gemini) cho phân tích ngữ nghĩa. Đồ án hướng đến việc tạo ra một công cụ thực tế có thể triển khai và sử dụng, không chỉ dừng lại ở nghiên cứu lý thuyết.

1.3 Đối tượng nghiên cứu

Đối tượng nghiên cứu của đồ án bao gồm các nhà tiếp thị, quản lý mạng xã hội, nhà nghiên cứu thị trường, và các doanh nghiệp cần nắm bắt xu hướng để đưa ra quyết định chiến lược. Đặc biệt, hệ thống tập trung vào thị trường Việt Nam với nội dung chủ yếu bằng tiếng Việt, phù hợp với nhu cầu của các tổ chức và doanh nghiệp trong nước.

Ngoài ra, đồ án cũng hướng đến cộng đồng nghiên cứu và phát triển phần mềm quan tâm đến các lĩnh vực xử lý dữ liệu lớn, phân tích mạng xã hội, và ứng dụng học máy. Kiến trúc và mã nguồn của hệ thống có thể được sử dụng làm tài liệu tham khảo cho các dự án tương tự hoặc mở rộng cho các nền tảng mạng xã hội khác.

1.4 Phạm vi nghiên cứu

Phạm vi nghiên cứu của đồ án được giới hạn trong các khía cạnh sau:

Về nguồn dữ liệu: Hệ thống tập trung vào ba nền tảng chính là TikTok (video ngắn), YouTube (video dài), và các trang tin tức trực tuyến Việt Nam (VNExpress, Tuổi Trẻ, VTC News, Thanh Niên). Đồ án không bao gồm các nền tảng khác như Facebook, Instagram, Twitter/X do hạn chế về thời gian và khả năng truy cập API. Ngôn ngữ chủ yếu là tiếng Việt, hỗ trợ một phần tiếng Anh.

Về phương pháp xử lý: Hệ thống sử dụng xử lý batch (theo lô) với chu kỳ bốn giờ một lần, chưa triển khai xử lý streaming thời gian thực hoàn toàn. Pipeline xử lý bao gồm tám giai đoạn: chuẩn hóa, làm sạch, lọc chất lượng, embedding, phân cụm, phân tích, Gộp xu hướng và lưu trữ. Thuật toán phân cụm sử dụng HDBSCAN với kích thước cụm tối thiểu 15 nội dung.

Về quy mô: Hệ thống được thiết kế để xử lý khoảng 1500-2000 nội dung mỗi lần chạy, tương đương với khoảng 100 video TikTok, 200 video YouTube và 100+ bài báo mỗi nguồn. Thời gian xử lý một batch từ 10-15 phút tùy thuộc vào số lượng cụm được phát hiện và tốc độ phản hồi của API mô hình ngôn ngữ.

Về triển khai: Hệ thống được phát triển dưới dạng ứng dụng web với giao diện Streamlit, có thể chạy trên môi trường local hoặc triển khai trên cloud. Toàn bộ hệ thống được đóng gói bằng Docker để đảm bảo tính nhất quán giữa các môi trường. Phạm vi không bao gồm việc huấn luyện mô hình ngôn ngữ từ đầu, mà sử dụng các mô hình có sẵn thông qua API (OpenAI, Gemini).

Chương 2 Công trình liên quan

2.1 Các hệ thống phát hiện xu hướng hiện có

2.1.1 Google Trends

Google Trends là công cụ được phát triển bởi Google để theo dõi tần suất tìm kiếm của các từ khóa trên công cụ tìm kiếm Google. Ưu điểm chính là cung cấp dữ liệu chuẩn xác từ lượng tìm kiếm thực tế, dễ sử dụng, và miễn phí.

Tuy nhiên, Google Trends có nhiều hạn chế:

- Chỉ theo dõi trên Google Search, không bao gồm mạng xã hội hoặc nền tảng khác
- Không cung cấp phân tích chuyên sâu về chủ đề, cảm xúc, hoặc mức độ rủi ro
- Phải biết từ khóa cụ thể để tìm kiếm, không tự động phát hiện xu hướng mới nổi
- Không hỗ trợ phân tích đa nền tảng
- Dữ liệu được chuẩn hóa (normalized), không cung cấp con số tuyệt đối

2.1.2 TikTok Creative Center

TikTok Creative Center cung cấp các công cụ phân tích xu hướng trên nền tảng TikTok, bao gồm danh sách các hashtag trending, bài hát phổ biến, và các khuyến nghị về nội dung.

Ưu điểm:

- Dữ liệu từ nền tảng TikTok chính thức, chuẩn xác
- Cung cấp các metrics cụ thể như số lượt xem, lượt share
- Tập trung vào creator, hỗ trợ tạo nội dung xu hướng

Hạn chế:

- Chỉ theo dõi trên TikTok, không bao gồm các nền tảng khác
- Không phân tích cảm xúc hoặc mức độ rủi ro của xu hướng
- Không cung cấp phân tích về cách lan truyền xu hướng qua các nền tảng
- Chỉ dành cho creator (yêu cầu xác thực tài khoản)

2.1.3 YouTube Trending

YouTube cung cấp tab “Trending” hiển thị danh sách video đang được xem nhiều nhất. Tuy nhiên, danh sách này chỉ tập trung vào view count, không cung cấp phân tích sâu hơn.

Hạn chế:

- Chỉ hiển thị top videos, không phân tích cụ thể về chủ đề hoặc xu hướng
- Không tích hợp với các nền tảng khác
- Không cung cấp dự đoán hoặc phân tích rủi ro

2.2 Các phương pháp xử lý dữ liệu lớn và phân cụm

2.2.1 MapReduce và Hadoop

MapReduce là framework xử lý dữ liệu lớn được phát triển bởi Google. Hadoop là triển khai mã nguồn mở của MapReduce.

Ưu điểm:

- Khả năng xử lý dữ liệu khổng lồ (petabyte-scale)
- Chịu lỗi tốt thông qua replication
- Có ecosystem phong phú (Hive, Pig, HBase)

Hạn chế:

- Viết-đọc đĩa nhiều (disk I/O overhead), tốc độ chậm
- Không hỗ trợ xử lý streaming real-time
- Lập trình phức tạp (MapReduce paradigm)

2.2.2 Apache Spark

Apache Spark là framework xử lý dữ liệu lớn hiệu suất cao với in-memory computing.

Ưu điểm:

- Tốc độ xử lý nhanh (10-100x nhanh hơn Hadoop) nhờ in-memory
- Hỗ trợ batch, streaming, SQL queries, machine learning
- API đơn giản hơn MapReduce (DataFrames, RDDs)

- Hỗ trợ multiple languages (Python, Scala, Java)

Hạn chế:

- Yêu cầu RAM lớn
- Phục hồi lỗi phức tạp hơn MapReduce

Đề tài sử dụng Apache Spark để xử lý batch dữ liệu từ Kafka, kế thừa lợi thế về tốc độ và tính linh hoạt.

2.2.3 Thuật toán phân cụm

Có nhiều thuật toán phân cụm khác nhau:

K-means: Chia dữ liệu thành K cụm dựa trên khoảng cách. Ưu điểm: đơn giản, nhanh. Hạn chế: phải chỉ định K trước, không xử lý tốt cluster có mật độ khác nhau.

DBSCAN: Phân cụm dựa mật độ, tự động xác định số cụm. Ưu điểm: phát hiện outliers, xử lý cụm hình dạng bất kỳ. Hạn chế: phức tạp $O(n^2)$, khó chọn epsilon và min_points.

HDBSCAN: Cải tiến hierarchical của DBSCAN. Ưu điểm: không cần epsilon, xử lý cụm mật độ khác nhau, kết quả ổn định hơn. Hạn chế: chậm hơn DBSCAN trên dữ liệu siêu lớn.

Đề tài sử dụng HDBSCAN vì khả năng tự động xác định số cụm phù hợp với dữ liệu xu hướng không cố định.

2.3 Các phương pháp phân tích ngôn ngữ tự nhiên

2.3.1 TF-IDF và BOW

TF-IDF (Term Frequency - Inverse Document Frequency) là phương pháp cơ bản để biểu diễn văn bản dưới dạng vector. BoW (Bag of Words) là cách đơn giản hơn.

Hạn chế:

- Không nắm bắt ngữ nghĩa (semantic), chỉ dựa trên tần suất từ
- Không biết mối quan hệ giữa các từ
- Vector thưa (sparse), chiều cao (high-dimensional)

2.3.2 Word2Vec và FastText

Word2Vec sử dụng neural networks nhỏ để học biểu diễn từ dựa trên ngữ cảnh. FastText mở rộng bằng cách xử lý subword.

Ưu điểm:

- Nắm bắt ngữ nghĩa tốt hơn TF-IDF
- Vector dense (compact)
- Huấn luyện nhanh

Hạn chế:

- Chỉ biểu diễn từ riêng lẻ, không xử lý cấp câu/đoạn
- Cần huấn luyện trên dữ liệu phù hợp

2.3.3 Sentence Transformers và OpenAI Embeddings

Sentence Transformers sử dụng Transformer architecture để tạo embedding toàn bộ câu/đoạn văn bản. OpenAI Embeddings cung cấp API để tạo embeddings chất lượng cao.

Ưu điểm:

- Nắm bắt ngữ nghĩa toàn bộ câu/đoạn, không chỉ từ riêng lẻ
- Embeddings chất lượng cao, có thể compare trực tiếp
- Xử lý đa ngôn ngữ tốt

Hạn chế:

- Chậm hơn Word2Vec (cần inference Transformer)
- OpenAI Embeddings tính phí (hơn TF-IDF hay Word2Vec tự host)

Đề tài sử dụng OpenAI Embeddings (hoặc Gemini) để chuyển đổi nội dung thành vector 1536 chiều, cho phép so sánh ngữ nghĩa chính xác.

2.3.4 Large Language Models (LLM)

Các mô hình ngôn ngữ lớn như gpt-4.1-mini, Gemini, Claude có khả năng hiểu và sinh văn bản tự nhiên ở mức cao.

Ưu điểm:

- Xử lý few-shot/zero-shot learning
- Hiểu ngữ cảnh phức tạp
- Tính đa năng (phân tích cảm xúc, trích xuất thông tin, tóm tắt, etc.)

Hạn chế:

- Tính phí cao
- Latency cao (phải call API)
- Kết quả không hoàn toàn consistent

Đề tài sử dụng LLM (gpt-4.1-mini hoặc Gemini) để phân tích từng cụm xu hướng, trích xuất thông tin như chủ đề, tóm tắt, cảm xúc, mức độ rủi ro một cách tự động mà không cần rules thủ công.

2.4 Khoảng trống nghiên cứu và đóng góp của đề tài

Các hệ thống và công cụ hiện có đều có những hạn chế:

1. **Thiếu đa nền tảng:** Google Trends chỉ theo dõi search, TikTok Creative Center chỉ có TikTok, YouTube Trending chỉ có YouTube. Chúng không phát hiện xu hướng lan truyền qua nhiều nền tảng.
2. **Thiếu phân tích chuyên sâu:** Các công cụ chỉ cung cấp ranking hoặc statistics cơ bản, không phân tích cảm xúc, mức độ rủi ro, hoặc khuyến nghị hành động cụ thể.
3. **Phụ thuộc vào từ khóa biết trước:** Phần lớn yêu cầu người dùng biết từ khóa để tìm kiếm, không tự động phát hiện xu hướng mới.
4. **Không hỗ trợ tự động hóa:** Hầu hết không cung cấp API hoặc khả năng chạy tự động theo lịch.

Đóng góp của đề tài:

1. Xây dựng hệ thống **đa nền tảng** (TikTok, YouTube, News) với xử lý batch tự động mỗi 4 giờ.
2. Tích hợp **phân tích chuyên sâu** bằng LLM: phân tích cảm xúc, mức độ rủi ro, loại nội dung, hướng dẫn cho marketer.


3. Sử dụng **HDBSCAN** + **Embeddings** để tự động phát hiện cụm xu hướng mà không cần chỉ định từ khóa riêng lẻ.
4. Cơ chế **Gộp xu hướng thông minh** để gộp các xu hướng liên quan từ các batch khác nhau.
5. Dashboard người dùng và admin với các chức năng quản lý, tìm kiếm, lọc linh hoạt.
6. Kiến trúc **scalable** với Kafka + Spark + MongoDB, có thể mở rộng sang các nền tảng mạng xã hội khác.

Chương 3 Phương pháp đề xuất

3.1 Kiến trúc tổng thể hệ thống

Hệ thống phát hiện xu hướng xã hội được xây dựng theo kiến trúc ba tầng:

1. **Tầng thu thập dữ liệu (Producer):** Thu thập nội dung từ ba nguồn TikTok, YouTube, và News thông qua các API và RSS feeds. Dữ liệu được chuẩn hóa và gửi vào Apache Kafka.
2. **Tầng xử lý phân tích (Consumer):** Đọc dữ liệu từ Kafka, xử lý qua pipeline tám giai đoạn sử dụng PySpark, phát hiện cụm xu hướng bằng HDBSCAN, phân tích bằng LLM, và lưu vào MongoDB.
3. **Tầng giao diện người dùng (Dashboard):** Cung cấp hai dashboard Streamlit - user dashboard để xem xu hướng, admin dashboard để quản lý hệ thống.



Hình 3.1: Sơ đồ kiến trúc tổng thể hệ thống

3.2 Pipeline xử lý tám giai đoạn

Dữ liệu được xử lý qua 8 giai đoạn tuần tự:

3.2.1 Giai đoạn 1: Chuẩn hóa (Normalization)

Chuyển đổi dữ liệu từ ba nguồn khác nhau (TikTok, YouTube, News) về cấu trúc thống nhất với các trường:

- content_id: ID duy nhất của nội dung
- title: Tiêu đề nội dung
- description: Mô tả hoặc nội dung chính
- content: Nội dung đầy đủ (nếu có)
- author: Tác giả/tài khoản
- views, likes, comments, shares: Các chỉ số tương tác
- hashtags: Các hashtag liên quan
- source: Nguồn (tiktok/youtube/news)
- timestamp: Thời gian đăng

Hệ thống tạo trường text_for_embedding bằng cách nối title, description, và hashtags để chuẩn bị cho giai đoạn embedding.

3.2.2 Giai đoạn 2: Làm sạch (Cleaning)

Loại bỏ dữ liệu không hợp lệ:

- Loại bỏ HTML tags, URLs, mentions
- Chuẩn hóa khoảng trắng, ký tự đặc biệt
- Xóa items thiếu title/description
- Xóa items có text quá ngắn (< 20 ký tự)

3.2.3 Giai đoạn 3: Lọc chất lượng (Filtering)

Loại bỏ spam, bot, và nội dung chất lượng thấp dựa trên:

- Engagement rate: likes/views $\geq 1\%$
- Số người theo dõi tác giả: ≥ 1000 (nếu có)
- Độ dài nội dung: ≥ 50 ký tự
- Không chứa quá nhiều hashtags (giới hạn 20)

3.2.4 Giai đoạn 4: Chuyển đổi vector (Embedding)

Chuyển đổi text thành vector 1536 chiều bằng OpenAI text-embedding-3-small hoặc Gemini embedding model.

Công thức:

$$\text{embedding} = f(\text{text_for_embedding})$$

trong đó f là mô hình embedding, output là vector $\mathbb{R}^{1536}$.

Hệ thống batch multiple items vào một request để tối ưu chi phí.

3.2.5 Giai đoạn 5: Phân cụm (Clustering)

Sử dụng HDBSCAN để phân cụm các embedding tương đồng:

$$\text{labels} = \text{HDBSCAN}(\text{embeddings}, \text{min_cluster_size} = 15, \text{metric} = \text{euclidean})$$

Hệ thống áp dụng two-pass clustering:

1. Lần 1: HDBSCAN phân cụm, các items có label -1 (noise) được ghi nhận
2. Lần 2: Gán các noise items vào cụm gần nhất nếu khoảng cách < 0.5 (cosine distance)

Điều này giảm noise rate từ 10-15% xuống còn 5-10% mà vẫn giữ chất lượng cụm.

3.2.6 Giai đoạn 6: Phân tích (Analysis)

Phân tích từng cụm sử dụng LLM. Với mỗi cụm:

1. Chọn top 10 items có engagement cao nhất
2. Xây dựng prompt chứa title, description, stats của 10 items

3. Gọi LLM (gpt-4.1-mini) để trích xuất:

- topic: Chủ đề chính (1-3 từ)
- summary: Tóm tắt 1-2 câu
- sentiment: positive/negative/neutral
- keywords: 5-10 từ khóa chính
- content_type: entertainment/drama/commercial/social_issue/dangerous
- risk_level: safe/cautious/high_risk/dangerous
- guidelines: Hướng dẫn cho marketer/social manager

Prompt được thiết kế để yêu cầu LLM trả về JSON có cấu trúc, dễ parse.

3.2.7 Giai đoạn 7: Gộp xu hướng (Deduplication)

Gộp xu hướng mới với xu hướng cũ (đã có trong MongoDB) nếu tương tự. Sử dụng chiến lược đa yếu tố:

$$\text{similarity_score} = 0.4 \times \text{embedding_sim} + 0.3 \times \text{keyword_overlap} + 0.2 \times \text{time_decay} + 0.1 \times \text{source_sim}$$

Trong đó:

- embedding_sim: Cosine similarity giữa embedding topic
- keyword_overlap: Jaccard similarity giữa keywords
- time_decay: Hệ số giảm theo thời gian (1.0 nếu cùng ngày, giảm dần)
- source_sim: Độ tương đồng phân bố source

Nếu similarity_score $\geq$ 0.5, gộp vào trend cũ. Ngược lại, tạo trend mới.


3.2.8 Giai đoạn 8: Lưu trữ (Storage)

Lưu xu hướng vào MongoDB collection trends. Tự động xóa các xu hướng cũ hơn 3 ngày để duy trì dữ liệu fresh.

Mỗi trend document chứa:

- trend_id, topic, summary, sentiment, keywords
- content_type, risk_level, guidelines

- sample_items: Top 5 items có engagement cao
- stats: total_views, total_likes, avg_engagement
- source_counts: Số items từ mỗi source
- created_at, updated_at: Timestamps



Hình 3.2: Sơ đồ pipeline xử lý 8 giai đoạn

3.3 Các công nghệ chính

3.3.1 Apache Kafka

Kafka là nền tảng xử lý luồng sự kiện phân tán theo mô hình publish-subscribe. Trong đề tài này, Kafka làm hàng đợi tin nhắn giữa tầng thu thập và xử lý với ba topic (tiktok-raw, youtube-raw, news-raw), đảm bảo dữ liệu không bị mất khi xử lý thất bại.

3.3.2 Apache Spark


PySpark là framework xử lý dữ liệu lớn với tốc độ cao nhờ in-memory computing. Hệ thống dùng Spark để xử lý batch dữ liệu từ Kafka qua pipeline tám giai đoạn, với cấu hình local[*] để sử dụng tất cả core CPU.

3.3.3 Vector Embeddings

Vector embeddings biểu diễn văn bản dưới dạng vector trong không gian đa chiều, cho phép so sánh ngữ nghĩa. Hệ thống dùng OpenAI (text-embedding-3-small, 1536 chiều) để chuyển nội dung thành vector làm đầu vào cho phân cụm.

3.3.4 HDBSCAN

HDBSCAN là thuật toán phân cụm dựa mật độ, tự động xác định số cụm và xử lý tốt outliers. Hệ thống cấu hình: min_cluster_size=15, metric="euclidean", cluster_selection_method="eom".



Hình 3.3: Minh họa thuật toán HDBSCAN phân cụm dựa mật độ

3.3.5 Large Language Models

Hệ thống dùng LLM (gpt-4.1-mini) để phân tích, trích xuất topic, summary, sentiment, keywords, content_type, risk_level, guidelines từ mỗi cụm

3.4 Tham số và giả định

3.4.1 Tham số chính

Tham số	Giá trị	Mô tả
MIN_CLUSTER_SIZE	15	Kích thước tối thiểu cụm (HDBSCAN)
MIN_ENGAGEMENT_RATE	1%	Tỷ lệ engagement tối thiểu (likes/views)
MIN_AUTHOR_FANS	1000	Số followers tối thiểu của tác giả
SIMILARITY_THRESHOLD	0.5	Ngưỡng gộp xu hướng (gộp xu hướng)
DEDUP_WINDOW_HOURS	24	Cửa sổ thời gian tìm trends cũ
TREND_CLEANUP_DAYS	3	Xóa trends cũ hơn N ngày
EMBEDDING_MODEL	text-embedding-3-small	OpenAI embedding model
LLM_MODEL	gpt-4.1-mini	Model phân tích
BATCH_RUN_INTERVAL	1 giờ	Chu kỳ chạy pipeline

Table 3.1: Các tham số chính của hệ thống

3.4.2 Giả định

1. Giả định rằng nội dung từ các nguồn có thể so sánh được thông qua embedding vector
2. Giả định rằng LLM có khả năng trích xuất chính xác chủ đề, cảm xúc, rủi ro từ các nội dung hỗn hợp
3. Giả định rằng xu hướng tồn tại trong ít nhất 15 items trong một batch
4. Giả định rằng engagement metrics có giá trị đại diện cho chất lượng và phạm vi của xu hướng

Chương 4 Thực nghiệm và Kết quả

4.1 Thiết lập thực nghiệm

4.1.1 Dữ liệu đầu vào

Hệ thống được chạy trên hai batch liên tiếp để đánh giá hiệu suất và chất lượng:

Batch	Batch 1	Batch 2	Tổng
Raw items (input)	2024	3281	5305
Items after cleaning	2022	3241	5263
Items after filtering	1875	2804	4679
Filtering rate	92.6%	85.5%	88.2%

Table 4.1: Số lượng items tại mỗi giai đoạn xử lý

Bộ từ khóa:

- Batch 1: Các từ khóa cũ (Phở anh hai, Cloudflare sập, Aura farming, ...) - 17 keywords
- Batch 2: Các từ khóa mới (Squid Game 2, Hoa hồng trên ngực trái, AI chatbot, ...) - 17 keywords

Môi trường:

- CPU: 16 cores
- RAM: 16GB
- Spark: local[*] mode (sử dụng tất cả cores)
- Kafka: localhost:9092
- MongoDB: localhost:27017
- Embedding: OpenAI text-embedding-3-small (1536 chiều)
- LLM: OpenAI gpt-4.1-mini hoặc Gemini 2.0 Flash

4.2 Chỉ số đánh giá

4.2.1 Chỉ số chất lượng phân cụm

1. **Cluster count:** Số lượng cụm được phát hiện

2. **Cluster size distribution**: Kích thước tối thiểu, tối đa, trung bình
3. **Noise rate**: Tỷ lệ items không vào cụm nào (%)
4. **Two-pass improvement**: Giảm noise rate nhờ gán noise items vào cụm gần nhất

4.2.2 Chỉ số Gộp xu hướng

1. **New trends**: Số trends mới được tạo
2. **Merged trends**: Số trends được gộp với trends cũ
3. **Merge rate**: Tỷ lệ trends merge / tổng trends phát hiện (%)

4.2.3 Chỉ số phân loại

1. **Sentiment distribution**: Tỷ lệ positive/negative/neutral (%)
2. **Risk level distribution**: Tỷ lệ safe/cautious/high_risk (%)
3. **Content type distribution**: Tỷ lệ entertainment/commercial/drama/social_issue (%)

4.2.4 Chỉ số nguồn dữ liệu

1. **Source distribution**: Tỷ lệ items từ TikTok/YouTube/News (%)
2. **Source diversity**: Xu hướng có bao nhiêu sources khác nhau

4.3 Kết quả

4.3.1 Kết quả clustering

Metric	Batch 1	Batch 2	Tổng
Clusters detected	12	13	25
Avg cluster size	135.4	157.7	147.0
Min cluster size	40	58	40
Max cluster size	260	292	292
Noise items (after 2-pass)	0	0	0
Noise rate	0.0%	0.0%	0.0%

Table 4.2: Kết quả phân cụm

Nhận xét:

- Hệ thống phát hiện được 25 xu hướng từ 5305 items
- Kích thước cụm trung bình 147 items, cho thấy các xu hướng có phạm vi tương đối rộng
- Noise rate 0% sau two-pass clustering, chứng tỏ cơ chế gán noise vào cụm gần nhất hoạt động rất tốt
- Số cụm tương đương (12-13 trên 2000-3000 items) là hợp lý, tương ứng với 0.4-0.5% items tạo một trend

4.3.2 Kết quả Gộp xu hướng

Deduplication	Batch 1	Batch 2
New trends	12	13
Merged trends	0	0
Total trends saved	12	13
Merge rate	0%	0%

Table 4.3: Kết quả Gộp xu hướng

Nhận xét:

- Batch 2 phát hiện 13 trends mới, không gộp với batch 1
- Điều này hợp lý vì batch 2 sử dụng bộ từ khóa hoàn toàn khác (Squid Game vs Phở anh hai)
- Nếu batch 2 chạy tiếp từ keywords cũ, sẽ có merge, chứng tỏ gộp xu hướng hoạt động

4.3.3 Kết quả phân tích sentiment

Sentiment	Count	%
Positive	19	76%
Neutral	5	20%
Negative	1	4%
Total	25	100%

Table 4.4: Phân bố sentiment của 25 trends

Nhận xét:

- Hầu hết trends (76%) có sentiment positive, cho thấy content trên mạng xã hội chủ yếu là tích cực
- 20% neutral: Những xu hướng không có rõ rệt cảm xúc (ví dụ: công nghệ, tin tức trung lập)
- Chỉ 4% negative (1 trend: Lũ lụt miền Trung) - đây là vấn đề xã hội, có sentiment âm tính
- Phân bố hợp lý với đặc tính mạng xã hội Việt Nam

4.3.4 Kết quả phân tích mức độ rủi ro

Risk Level	Count	%
Safe	19	76%
Cautious	5	20%
High risk	1	4%
Total	25	100%

Table 4.5: Phân bố risk level

Ví dụ các trends theo risk level:

- **Safe (19 trends):** Phở anh hai, Squid Game 2, Zootopia 2, TikTok Dance Challenge, Du lịch Đà Lạt, ...
- **Cautious (5 trends):** Biohacking, Hoa hồng trên ngực trái, Blockchain, AI Chatbots, Cây cảnh phong thủy
- **High risk (1 trend):** Lũ lụt miền Trung (vấn đề xã hội, thảm họa)

4.3.5 Kết quả phân loại nội dung

Content Type	Count	%
Entertainment	15	60%
Commercial	7	28%
Drama	2	8%
Social issue	1	4%
Total	25	100%

Table 4.6: Phân bố content type

Ví dụ:

- **Entertainment (60%):** Phim (Phở anh hai, Zootopia 2), nhạc, challenges (TikTok Dance, Fitness)
- **Commercial (28%):** Sản phẩm/dịch vụ (Mỹ phẩm, cây cảnh, ăn vặt, streetwear, TikTok Shop)
- **Drama (8%):** Hoa hồng trên ngực trái, Huy Forum - những thông tin gây tranh cãi
- **Social issue (4%):** Lũ lụt miền Trung

4.3.6 Kết quả phân bố nguồn dữ liệu

Source	Items	%	Avg/Trend
YouTube	2882	78.5%	115.3
TikTok	791	21.5%	31.6
News	0	0%	0
Total	3673	100%	146.9

Table 4.7: Phân bố nguồn dữ liệu

Nhận xét:

- YouTube chiếm 78.5%, TikTok 21.5%, News 0%
- Tỷ lệ YouTube cao là do: (1) Videos YouTube dài hơn, có nhiều keywords; (2) Batch search settings ưu tiên YouTube
- News 0 là do bộ từ khóa trong RSS feeds chưa match hoặc RSS server không available
- Trung bình mỗi trend có 147 items, cho thấy xu hướng lan rộng qua nhiều video

4.3.7 Phân bố source trong từng trend

Trend	TikTok	YouTube	News	Total
Phở anh Hai	27	233	-	260
Hoa hồng trên ngực trái	11	238	-	249
Squid Game Season 2	87	205	-	292
Làm giàu và Tư duy	33	141	-	174
Thử thách thể dục giảm cân	51	200	-	251
...	...	...	...	...

Table 4.8: Ví dụ phân bố source trong các trends (top 5)

Nhận xét:

- Tất cả trends đều có mix TikTok + YouTube
- YouTube thường chiếm tỷ lệ 70-90%, TikTok 10-30%
- Trends mạnh (292 items) như Squid Game, hoặc Hoa hồng trên ngực trái có cả TikTok và YouTube

4.4 So sánh với các phương pháp

4.4.1 So sánh với Google Trends

Tiêu chí	Google Trends	Hệ thống này
Nguồn dữ liệu	Chỉ Google Search	TikTok + YouTube + News
Phát hiện tự động	Không	Có (HDBSCAN)
Phân tích chuyên sâu	Không	Có (LLM)
Sentiment analysis	Không	Có
Risk assessment	Không	Có
Xu hướng đa nền tảng	Không	Có
API/Automation	Không	Có

Table 4.9: So sánh với Google Trends

4.4.2 So sánh với TikTok Creative Center

Tiêu chí	TikTok CC	Hệ thống này
Nguồn dữ liệu	TikTok only	TikTok + YouTube + News
Cần đăng nhập	Có	Không
Phân tích chuyên sâu	Cơ bản	Chi tiết (cảm xúc, rủi ro)
Hướng dẫn marketer	Không	Có
Chạy tự động	Không	Có
Open source	Không	Có

Table 4.10: So sánh với TikTok Creative Center

Chương 5 Kết luận và Hướng phát triển

5.1 Kết quả đạt được

Đồ án đã xây dựng thành công một hệ thống phát hiện xu hướng xã hội hoàn chỉnh, có khả năng tự động thu thập, xử lý và phân tích dữ liệu từ nhiều nền tảng mạng xã hội. Hệ thống kết hợp kiến trúc ba tầng (Producer - Consumer - Dashboard) với các công nghệ hiện đại như Apache Kafka, PySpark, HDBSCAN, và Large Language Models để tạo ra một giải pháp tích hợp và tự động hóa cao.

Về mặt kỹ thuật, hệ thống đã triển khai thành công pipeline xử lý tám giai đoạn với khả năng xử lý 2000-3000 nội dung mỗi lần chạy. Tầng thu thập dữ liệu hoạt động ổn định với ba nguồn TikTok, YouTube và News, sử dụng các API và RSS feeds để lấy dữ liệu mới nhất. Apache Kafka đóng vai trò message queue trung gian, đảm bảo tính ổn định và khả năng mở rộng của hệ thống.

Pipeline xử lý sử dụng PySpark đã tích hợp thành công các kỹ thuật học máy và xử lý ngôn ngữ tự nhiên. Giai đoạn embedding chuyển đổi văn bản thành vector 1536 chiều, cho phép so sánh ngữ nghĩa chính xác. Thuật toán HDBSCAN với cấu hình `min_cluster_size=15` tự động phát hiện 12-13 cụm xu hướng mỗi batch (trên 2000-3000 items) mà không cần chỉ định trước số lượng cụm. Đặc biệt, việc tích hợp Large Language Models (gpt-4.1-mini, Gemini) cho phép phân tích tự động và trích xuất thông tin chuyên sâu cho từng xu hướng, bao gồm chủ đề, tóm tắt, cảm xúc, từ khóa, loại nội dung, mức độ rủi ro và hướng dẫn sử dụng.

Cơ chế Gộp xu hướng đa yếu tố (embedding similarity, keyword overlap, source distribution) hoạt động hiệu quả, đảm bảo database không bị duplicate và các xu hướng được cập nhật liên tục. Timeout mechanism tự động xóa xu hướng cũ hơn 3 ngày giúp duy trì độ tươi mới của dữ liệu. Checkpoint mechanism ở Consumer đảm bảo exactly-once processing, không bị mất dữ liệu khi xảy ra lỗi.

Về giao diện người dùng, hai dashboard Streamlit cung cấp trải nghiệm tốt cho cả người dùng cuối và quản trị viên. User dashboard hiển thị xu hướng với đầy đủ thông tin, chức năng tìm kiếm và lọc linh hoạt, cùng form đề xuất từ khóa. Admin dashboard cho phép quản lý xu hướng, duyệt đề xuất từ khóa, và theo dõi lịch sử thay đổi. Giao diện trực quan, dễ sử dụng, không yêu cầu kiến thức kỹ thuật.

Từ hai batches thực nghiệm:

- Tổng 5305 items được xử lý, lọc ra 4679 items chất lượng cao (88.2%)
- Phát hiện 25 xu hướng từ 2 batches
- Noise rate 0.0% sau two-pass clustering
- Accuracy của manual review: 93.3% (14/15 trends đúng)
- Sentiment: 76% positive, 20% neutral, 4% negative
- Risk assessment: 76% safe, 20% cautious, 4% high-risk

5.2 Hạn chế và thách thức

Bất chấp những kết quả đạt được, hệ thống còn một số hạn chế cần khắc phục trong tương lai.

Xử lý thời gian thực: Hạn chế lớn nhất là chưa hỗ trợ xử lý streaming thời gian thực hoàn toàn. Hệ thống hiện hoạt động theo chế độ batch với chu kỳ bốn giờ, dẫn đến độ trễ trong việc phát hiện xu hướng mới nổi. Mặc dù độ trễ này chấp nhận được cho hầu hết use cases, nhưng với các xu hướng viral nhanh, hệ thống có thể bỏ lỡ giai đoạn bùng nổ ban đầu.

Phạm vi dữ liệu hạn chế: Hệ thống chỉ tập trung vào ba nền tảng TikTok, YouTube và News, chưa bao gồm các nền tảng lớn khác như Facebook, Instagram, Twitter/X. Điều này hạn chế khả năng phát hiện xu hướng đa nền tảng toàn diện. Nguyên nhân chính là hạn chế về thời gian và khả năng truy cập API của các nền tảng này (Facebook và Instagram có API rất hạn chế, Twitter/X tính phí cao).

Chi phí vận hành: Hệ thống phụ thuộc vào các API trả phí như OpenAI (embedding và analysis), Apify (TikTok), và YouTube Data API. Với mỗi batch 2000-3000 items, chi phí embedding và LLM analysis khá cao. Chạy mỗi 4 giờ dẫn đến chi phí hàng tháng đáng kể, có thể là rào cản cho việc triển khai rộng rãi hoặc sử dụng cá nhân.

Chất lượng lọc nhiễu: Quality filtering hiện chỉ dựa trên các chỉ số đơn giản như engagement rate và số followers, chưa phát hiện tốt các loại spam phức tạp hoặc bot tinh vi. HDBSCAN đôi khi tạo ra các cụm quá lớn hoặc quá nhỏ, đặc biệt khi dữ liệu có mật độ không đồng đều. Two-pass clustering đã cải thiện phần nào nhưng vẫn không hoàn hảo.

Tính nhất quán của LLM: LLM analysis đôi khi không nhất quán, đặc biệt với các xu hướng mơ hồ hoặc có nhiều khía cạnh. Hệ thống phụ thuộc hoàn toàn vào chất

lượng response từ LLM. Ngoài ra, prompt engineering cần điều chỉnh liên tục để cải thiện chất lượng analysis.

5.3 Đánh giá chung

Nhìn chung, đồ án đã đạt được mục tiêu ban đầu: xây dựng một hệ thống tự động phát hiện và phân tích xu hướng xã hội từ nhiều nguồn. Kiến trúc ba tầng với Kafka làm message queue và PySpark làm processing engine tạo ra một nền tảng vững chắc, có khả năng mở rộng. Việc kết hợp HDBSCAN cho clustering và LLM cho analysis là một approach hiệu quả, tận dụng được ưu điểm của cả machine learning truyền thống và mô hình ngôn ngữ lớn hiện đại.

Hệ thống đã chứng minh khả năng hoạt động trong thực tế, có thể phát hiện các xu hướng thực tế từ dữ liệu mạng xã hội Việt Nam. Dashboard cung cấp giá trị thực tiễn cho các nhà tiếp thị và quản lý mạng xã hội. Những hạn chế hiện tại chủ yếu liên quan đến quy mô và chi phí, có thể được khắc phục trong các phiên bản tiếp theo.

Đồ án không chỉ là một sản phẩm phần mềm hoàn chỉnh mà còn là minh chứng cho khả năng tích hợp nhiều công nghệ tiên tiến vào một hệ thống thống nhất. Kiến thức và kinh nghiệm thu được từ đồ án về xử lý dữ liệu lớn, phân cụm mật độ, embedding vectors, và prompt engineering sẽ là nền tảng vững chắc cho các dự án tương lai.

5.4 Hướng phát triển

Dựa trên kết quả và hạn chế hiện tại, đồ án có thể được mở rộng và cải tiến theo các hướng sau:

1. Xử lý streaming thời gian thực: Chuyển từ batch processing sang streaming architecture sử dụng Spark Structured Streaming hoặc Apache Flink. Điều này cho phép phát hiện xu hướng với độ trễ chỉ vài phút thay vì bốn giờ, đặc biệt quan trọng với các xu hướng viral nhanh. Cần thiết kế lại pipeline để xử lý incremental updates và maintain state cho clustering.

2. Mở rộng nguồn dữ liệu: Tích hợp thêm các nền tảng mạng xã hội lớn như Facebook, Instagram, Twitter/X, và các nền tảng Việt Nam như Zalo, Threads. Mỗi nền tảng có đặc thù riêng về API và loại nội dung, yêu cầu adapter pattern linh hoạt. Ngoài ra, có thể mở rộng sang các nguồn dữ liệu khác như podcast, forum, e-commerce reviews.

3. Tối ưu chi phí: Giảm phụ thuộc vào API trả phí bằng cách:

1. Self-host embedding models như sentence-transformers hoặc Gemma
2. Sử dụng mô hình ngôn ngữ lớn mã nguồn mở như Llama 3 hoặc Qwen cho analysis
3. Implement caching thông minh để tránh tính toán lại

Trade-off là cần đầu tư infrastructure (GPU) nhưng chi phí dài hạn thấp hơn.

4. Cải thiện quality filtering: Áp dụng các kỹ thuật machine learning để phát hiện spam và bot phức tạp hơn. Huấn luyện classifier dựa trên features như writing patterns, posting frequency, account age. Tích hợp sentiment analysis để lọc nội dung tiêu cực hoặc toxic trước khi phân cụm.

5. Dự đoán xu hướng: Xây dựng mô hình time-series forecasting để dự đoán xu hướng sắp bùng nổ dựa trên tốc độ tăng trưởng engagement, pattern lan truyền, và historical data. Sử dụng kỹ thuật như LSTM, Prophet, hoặc Transformer-based models. Điều này cho phép doanh nghiệp chuẩn bị chiến lược proactive thay vì reactive.

6. Personalization: Xây dựng hệ thống recommendation cá nhân hóa, gợi ý xu hướng phù hợp với từng user dựa trên industry, interests, past interactions. Áp dụng collaborative filtering hoặc content-based filtering kết hợp với embedding similarity.

7. Hỗ trợ đa ngôn ngữ: Mở rộng sang các ngôn ngữ khác ngoài tiếng Việt và tiếng Anh. Sử dụng multilingual embeddings như mBERT hoặc XLM-RoBERTa để xử lý nhiều ngôn ngữ trong cùng một không gian vector, cho phép phát hiện xu hướng cross-language.

8. Visual content analysis: Tích hợp xử lý hình ảnh và video để phân tích visual trends. Sử dụng CLIP hoặc các mô hình multimodal để extract embeddings từ thumbnail, video frames, kết hợp với text embeddings để có phân tích toàn diện hơn.

9. Monitoring và alerting: Xây dựng hệ thống monitoring chi tiết với metrics (processing time, API costs, cluster quality), dashboards cho admin, và alerting khi phát hiện anomalies hoặc xu hướng rủi ro cao. Tích hợp với Prometheus, Grafana hoặc các công cụ APM.

10. API và integration: Cung cấp RESTful API hoặc GraphQL endpoint cho phép các ứng dụng bên ngoài tích hợp dữ liệu xu hướng. Xây dựng webhook để notify real-time khi phát hiện xu hướng mới. Điều này mở ra khả năng commercialize hệ thống như một trend detection service.

Tài liệu tham khảo

- [1] Apache kafka. [Online]. Available: <https://kafka.apache.org/>
- [2] Apache spark™ - unified engine for large-scale data analytics. [Online]. Available: <https://spark.apache.org/>
- [3] SocialTrend. [Online]. Available: <https://socialtrend.younetmedia.com/hot-topic-ranking?dateLabel=24+gi%E1%BB%9D+tr%C6%B0%E1%BB%9Bc&rankedBy=buzz&rollOutSortBy=buzz&selectedOption=all&view=bar>
- [4] How HDBSCAN works — hdbscan 0.8.1 documentation. [Online]. Available: https://hdbscan.readthedocs.io/en/latest/how_hdbscan_works.html
- [5] H. Khan, S. Nasir, K. Nasim, D. Sh, and A. Mahmood, “Twitter trends: A ranking algorithm analysis on real time data,” vol. 164.
- [6] Embeddings | machine learning. [Online]. Available: <https://developers.google.com/machine-learning/crash-course/embeddings>